

LAPORAN PROYEK STBI
SISTEM INFORMATION RETRIEVAL BERBASIS BM25
PADA PLATFORM OPENMRS

*Normalisasi dan Ekspansi Klinis untuk Pencarian Catatan Medis Teks
Bebas*



Oleh:

ADE DWI PRAYITNO (25/563076/PPA/07097)
ALDI INDRAWAN (25/557923/PPA/07038)
ARI RUDIATAMA (25/569437/PPA/07170)
DIMAS IHDAM MAULANA (25/562999/PPA/07090)
WILADAHTUL AWALIAH (25/569610/PPA/07174)

PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA

2026

Abstrak

Sistem Information Retrieval Berbasis BM25 pada Platform OpenMRS: Normalisasi dan Ekspansi Klinis untuk Pencarian Catatan Medis Teks Bebas

Pencarian pada Rekam Medis Elektronik (RME) konvensional umumnya terbatas pada pencocokan kata kunci eksak, sehingga gagal menangani sinonim, singkatan, dan variasi terminologi medis pada catatan klinis teks bebas. Proyek ini mengimplementasikan mesin *ranked retrieval* berbasis BM25 dan mengintegrasikannya ke dalam platform open-source OpenMRS sebagai modul tambahan. Kontribusi utamanya bukan sekadar penerapan BM25, melainkan studi ablasi terhadap lapisan **normalisasi dan ekspansi klinis**: stopword list yang mempertahankan penanda negasi, deteksi istilah majemuk, serta ekspansi singkatan dan sinonim medis. Sistem dievaluasi pada dataset MTSamples yang diproses menjadi 2.316 dokumen final, dengan lima varian retrieval (V0–V4) yang dibandingkan berdampingan. Hasil menunjukkan bahwa normalisasi klinis (V1) meningkatkan nDCG@10 dari 0,6832 menjadi 0,6865 dibanding baseline naif (V0), sementara varian ekspansi menunjukkan *trade-off* presisi yang dilaporkan apa adanya. Modul yang dihasilkan diuji berjalan pada OpenMRS 2.8.8 dengan indeks Apache Lucene 8.11.2 yang di-*shade* untuk menghindari konflik dependensi.

Sistem Information Retrieval Berbasis BM25 pada Platform OpenMRS: Normalisasi dan Ekspansi Klinis untuk Pencarian Catatan Medis Teks Bebas

1 Pendahuluan

Penerapan Rekam Medis Elektronik telah menjadi standar esensial dalam layanan kesehatan modern. Platform open-source seperti OpenMRS digunakan oleh lebih dari 8.000 fasilitas kesehatan di lebih dari 70 negara untuk mengelola data pasien secara elektronik (Syzdykova dkk., 2017). OpenMRS menyimpan data klinis dalam berbagai bentuk, termasuk *observations*, *encounters*, *diagnoses*, dan catatan klinis teks bebas seperti *discharge summary*, laporan radiologi, dan *progress notes*.

Namun, kemampuan pencarian pada sistem RME konvensional umumnya terbatas pada pencarian eksak berbasis query SQL sederhana. Pendekatan ini tidak efektif untuk menemukan kasus klinis yang relevan dari catatan medis teks bebas karena tidak memahami sinonim, variasi terminologi medis, maupun konteks semantik. Sebagai contoh, dokter yang mencari pasien dengan “gangguan ginjal kronis” mungkin tidak menemukan catatan yang memakai istilah “CKD” atau “penyakit ginjal kronis” bila sistem hanya mendukung pencarian kata kunci eksak.

Information Retrieval (IR) menawarkan pencarian berbasis konten yang mampu menangkap relevansi antara *query* dan isi dokumen medis. Algoritma *ranked retrieval* seperti BM25 terbukti menjadi metode yang andal untuk pencarian teks pada koleksi berskala besar, termasuk domain medis dengan variasi panjang dokumen yang ekstrem (Robertson and Zaragoza, 2009). Proyek ini mengimplementasikan modul IR berbasis BM25 pada OpenMRS dan mengevaluasinya dengan dataset publik MTSamples.

1.1 Rumusan Masalah

Pencarian informasi medis pada RME lama masih mengandalkan mekanisme pencarian kata kunci eksak yang membatasi efektivitas penemuan kasus klinis. Pendekatan ini gagal menangani variasi terminologi medis, singkatan, dan sinonim, sehingga dokumen relevan yang memakai istilah berbeda tidak dapat ditemukan. Akibatnya, tenaga medis kesulitan mengakses riwayat klinis pasien secara komprehensif, yang berpotensi menghambat kecepatan dan akurasi pengambilan keputusan medis.

1.2 Batasan

Batasan proyek ini adalah sebagai berikut.

1. Platform yang digunakan adalah OpenMRS Reference Application, bukan pengembangan RME dari nol.
2. Algoritma yang diimplementasikan adalah BM25, tidak mencakup pendekatan *neural retrieval*.
3. Dataset yang digunakan adalah MTSamples yang memuat sekitar 5.000 transkripsi medis.
4. Modul diintegrasikan melalui endpoint HTTP tanpa mengubah skema basis data inti OpenMRS.
5. Evaluasi dilakukan secara teknis menggunakan metrik IR standar tanpa uji klinis dengan pasien nyata.

1.3 Tujuan

Tujuan proyek ini adalah mengimplementasikan *ranked retrieval* BM25, membangun mekanisme pengindeksan dengan *inverted index*, mengintegrasikan modul pencarian ke ekosistem OpenMRS, dan mengevaluasi kinerjanya dengan metrik Precision@K, Recall@K, dan nDCG@K.

2 Tinjauan Pustaka

2.1 Information Retrieval dalam Rekam Medis Elektronik

Sistem IR pada RME memungkinkan pencarian kasus klinis berdasarkan isi teks medis, bukan hanya metadata pasien. Berbeda dengan pencarian basis data relasional yang bergantung pada *exact-match*, IR menggunakan model probabilistik atau vektorial untuk menentukan relevansi dokumen terhadap *query*. Dalam domain klinis, tantangan IR meliputi variasi terminologi medis (sinonim), singkatan, dan dokumen dengan panjang yang sangat bervariasi, mulai dari laporan radiologi yang singkat hingga *surgery report* yang panjang (Manning dkk., 2008).

2.2 Algoritma BM25

BM25 adalah model probabilistik perankingan dokumen yang dikembangkan oleh Robertson dkk. dan merupakan evolusi dari model klasik TF-IDF (Robertson and Zaragoza, 2009). BM25 memperhitungkan tiga komponen utama: *term frequency* (TF) yang di-*saturate* untuk menghindari dominasi kata yang sangat sering muncul, *inverse document frequency* (IDF) yang mengukur keunikan kata dalam koleksi, dan normalisasi panjang dokumen. Skor BM25 untuk dokumen D dan *query* Q dihitung sebagai

$$\text{score}(D, Q) = \sum_{q_i \in Q} \text{IDF}(q_i) \cdot \frac{\text{TF}(q_i, D) (k_1 + 1)}{\text{TF}(q_i, D) + k_1 \left(1 - b + b \frac{|D|}{\text{avgdl}}\right)}$$

dengan k_1 dan b sebagai parameter *tuning*. BM25 dipilih karena terbukti superior untuk koleksi dokumen dengan variasi panjang yang ekstrem, sebagaimana pada catatan medis.

2.3 Platform OpenMRS

OpenMRS adalah platform RME open-source berbasis Java dengan arsitektur modular di atas Spring Framework. Platform ini mendukung pengembangan modul tambahan (*OpenMRS Module*) yang dapat dipasang secara independen tanpa mengganggu sistem inti, serta menyediakan REST API bawaan untuk integrasi dengan aplikasi eksternal (OpenMRS, 2026).

2.4 Dataset MTSamples

MTSamples adalah dataset publik yang berisi sekitar 5.000 transkripsi medis dari 40 spesialisasi klinis, tersedia di Kaggle (MTSamples, 2020). Setiap sampel memuat kolom `medical_specialty`, `sample_name`, `description`, `transcription`, dan `keywords`. Kolom `transcription` berisi paragraf narasi medis lengkap yang secara struktural mirip dengan catatan klinis pada RME.

2.5 Gap Penelitian

Kajian pustaka lanjutan menunjukkan bahwa BM25 pada dataset MTSamples sudah pernah diuji, namun selalu diperlakukan sebagai *baseline* naif, bukan sebagai objek optimasi tokenisasi. Tabel 1 merangkum perbandingannya.

Tabel 1: Perbandingan studi terkait dan perlakuan terhadap BM25.


Studi	Fokus	Perlakuan terhadap BM25
Mikkelsen (2026)	Benchmark <i>embedding</i> vs BM25	Baseline dengan tokenisasi lowercase + hapus tanda baca
Zhang (2021)	Optimasi bobot skor BM25	Perbaikan di fungsi skor, bukan tokenisasi
Gayen dkk. (2023)	Porting tokenisasi Essie ke Solr	Tokenisasi klinis, bukan untuk BM25 di RME
Griffon dkk. (2012)	Ekspansi sinonim UMLS	Untuk PubMed, bukan untuk RME

Berdasarkan perbandingan tersebut, gap yang diisi proyek ini adalah belum adanya studi yang secara khusus mengevaluasi lapisan normalisasi dan ekspansi sinonim/singkatan klinis untuk algoritma BM25 pada dataset MTSamples, apalagi yang diintegrasikan langsung ke OpenMRS.

3 Metodologi

3.1 Arsitektur Sistem

Sistem terdiri atas tiga komponen utama: pipeline data (Python), mesin IR (Java/Lucene), dan modul OpenMRS. Gambar 1 mengilustrasikan alur sistem.



Gambar 1: Arsitektur sistem IR berbasis BM25 pada OpenMRS.

3.2 Pipeline Data

Dataset dibangun dari `mtsamples.csv` (4.999 baris) melalui tiga tahap: deduplikasi, normalisasi *whitespace*, dan penyaringan dokumen pendek. Baris duplikat digabung (bukan dibuang) sehingga metadata multi-label dipertahankan. Lexicon klinis dibangun dari empat sumber: penanda negasi, istilah majemuk, singkatan medis, dan sinonim. Query set berisi 50 *query* klinis, dengan *relevance judgment* (qrels) format TREC yang disusun secara semi-otomatis berbasis kolom `keywords`, `sample_name`, dan `description`, serta sadar-sinonim agar varian ekspansi dinilai setara.

3.3 Varian Retrieval

Seluruh varian memakai parameter BM25 yang sama ($k_1 = 1,2$, $b = 0,75$). Perbedaannya hanya pada lapisan tokenisasi. Tabel 2 merangkum kelima varian.

Tabel 2: Lima varian retrieval pada ablation study.

ID	Label	Strategi
V0	Naive BM25	lowercase + hapus tanda baca (baseline)
V1	Normalisasi klinis	V0 + negasi dipertahankan + istilah majemuk + ekspansi singkatan
V2	Klinis + ekspansi	V1 + ekspansi sinonim query-side
V3	Char n-gram	indexing karakter n-gram (3–5)
V4	Klinis + ekspansi + PRF	V2 + <i>pseudo-relevance feedback</i>

Kelima varian dirancang sebagai *ablation study*, bukan sebagai lima mode produksi yang setara: V0 berfungsi sebagai kontrol untuk mengukur kontribusi murni dari setiap lapisan tokenisasi yang ditambahkan bertahap. V1 menjawab kebutuhan istilah klinis dasar (negasi, istilah majemuk, singkatan) yang lazim pada catatan medis. V2 menjawab langsung rumusan masalah utama, yaitu kesenjangan istilah antara *query* dokter dan istilah dalam dokumen (misalnya “CKD” vs. “penyakit ginjal kronis”). V3 diuji sebagai pendekatan alternatif berbasis karakter yang tahan terhadap variasi morfologi dan salah ketik tanpa bergantung pada *lexicon* manual. V4 menguji apakah ekspansi otomatis berbasis *pseudo-relevance feedback* dapat menyamai atau melampaui ekspansi manual pada V2. Dengan menjaga parameter BM25 identik pada seluruh varian, perbedaan hasil evaluasi pada Tabel 5 dapat diatribusikan secara adil ke lapisan tokenisasi masing-masing.

4 Implementasi

4.1 Pembangunan Dataset dan Lexicon

Dataset final berisi 2.316 dokumen dari 4.999 baris mentah. Statistiknya dirangkum pada Tabel 3. Temuan penting adalah 91,2% dokumen bersifat multi-spesialisasi, sehingga kolom `medical_specialty` tidak dapat dijadikan *ground-truth* relevansi untuk evaluasi.

Tabel 3: Statistik pembangunan dataset final.

Metrik	Nilai
Baris mentah	4.999
Transkripsi kosong	33
Baris duplikat	2.609
Dokumen < 50 token	41
Dokumen final	2.316
Multi-spesialisasi	91,2%

Lexicon klinis yang dibangun beserta cakupannya pada dataset disajikan pada Tabel 4. Pengukuran dilakukan langsung pada `corpus.jsonl` untuk memastikan urgensi tokenisasi klinis berbasis bukti, bukan asumsi.

Tabel 4: Komponen lexicon klinis dan cakupan pada dataset (2.316 dokumen).


Kategori	Jumlah	Cakupan
Penanda negasi (no, denies, without)	13	88,0%
Istilah majemuk (shortness of breath)	28	60,9%
Singkatan medis (c/o, DM, HTN)	28	28,8%
Grup sinonim	15	–

4.2 Mesin IR berbasis Lucene

Mesin IR ditulis dalam Java dengan Apache Lucene 8.11.2. Karena OpenMRS membundel Lucene versi lama (tanpa BM25), Lucene 8 di-*shade* dengan relokasi paket ke `org.openmrs.module.irbm25.shaded.lucene` agar tidak bentrok. Indeks dibangun secara multi-field (`content_naive`, `content_clinical`, `content_ngram`) sehingga kelima varian dapat dibandingkan secara adil pada satu dataset dengan parameter BM25 yang identik.

4.3 Integrasi OpenMRS

Modul dikemas sebagai `.omod` dan mengekspos endpoint `GET/module/ir-bm25/search.json?q={keyword}&variant={v0..v4}&limit={k}` yang mengembalikan dokumen terurut beserta skor dan *snippet*. Antarmuka pengguna menyediakan *dropdown* untuk memilih varian serta mode “bandingkan semua” yang menampilkan kelima varian berdampingan. Fungsi *dropdown* ini bukan sekadar navigasi, melainkan alat *ablation study* interaktif: pengguna (atau evaluator) dapat langsung mengamati perbedaan hasil pencarian antar-lapisan tokenisasi untuk *query* yang sama, tanpa perlu menjalankan ulang *pipeline* evaluasi secara terpisah. Link navigasi ditambahkan ke *sidebar* Legacy UI melalui extension `org.openmrs.gutter.tools`. Gambar 2 menampilkan tangkapan layar mode perbandingan.



Gambar 2: Tampilan mode “bandingkan semua” kelima varian pada OpenMRS (query “hypertension”).

5 Hasil dan Evaluasi

Evaluasi dilakukan pada 50 *query* dengan *cutoff* $K = 10$, menggunakan metrik Precision@10, Recall@10, dan nDCG@10. Hasilnya disajikan pada Tabel 5.

Hasil menunjukkan bahwa V1 (normalisasi klinis) sedikit mengungguli baseline naif V0 pada P@10 dan nDCG@10, yang mendukung kontribusi lapisan tokenisasi

Tabel 5: Hasil evaluasi ablation study (50 query, K = 10).

Varian	P@10	Recall@10	nDCG@10
V0 · Naive BM25	0,5400	0,4312	0,6832
V1 · Normalisasi klinis	0,5420	0,4284	0,6865
V2 · Klinis + ekspansi	0,5120	0,4192	0,6509
V3 · Char n-gram	0,5280	0,4055	0,6446
V4 · Klinis + ekspansi + PRF	0,5020	0,4139	0,6186

klinis. Sementara itu, V2 dan V4 menurunkan presisi pada qrels ini, yang merupakan *trade-off* wajar dari ekspansi. Hal ini dilaporkan apa adanya dan menjadi arah untuk penyusunan qrels manual oleh klinisi pada tahap berikutnya. Secara fungsional, ekspansi singkatan terverifikasi bekerja: *query* “CKD” berhasil menemukan dokumen berjudul “Chronic Kidney Disease - Followup”, dan *query* “hypertension” menemukan dokumen yang memuat singkatan “HTN”.

6 Kesimpulan

Proyek ini berhasil mengimplementasikan mesin *ranked retrieval* BM25 dengan lapisan normalisasi dan ekspansi klinis, mengintegrasikannya ke OpenMRS sebagai modul tambahan, serta mengevaluasinya melalui ablation study lima varian pada dataset MTSamples. Validasi berbasis dataset menunjukkan bahwa penanda negasi, istilah majemuk, dan singkatan medis muncul pada sebagian besar dokumen, sehingga tokenisasi klinis bukan sekadar asumsi. Hasil evaluasi menunjukkan perbaikan kecil namun konsisten dari normalisasi klinis (V1) dibanding baseline naif, sekaligus mengungkap *trade-off* presisi pada varian ekspansi yang perlu ditindaklanjuti dengan *relevance judgment* manual. Modul teruji berjalan pada OpenMRS 2.8.8 dan siap digunakan sebagai purwarupa pencarian cerdas bagi tenaga medis.

Pustaka

Manning, C. D., Raghavan, P. and Schütze, H. (2008), *Introduction to Information Retrieval*, Cambridge University Press, Cambridge.

MTSamples (2020), ‘Medical transcription samples’.

URL: <https://www.kaggle.com/datasets/tboyle10/medicaltranscriptions>

OpenMRS (2026), ‘Openmrs source code repository and documentation’.

URL: <https://github.com/openmrs>

Robertson, S. and Zaragoza, H. (2009), ‘The probabilistic relevance framework: BM25 and beyond’, *Foundations and Trends in Information Retrieval* **3**(4), 333–389.

Syzdykova, A., Zieliński, K. and Jackowski, T. (2017), ‘Open-source electronic health record systems for low-resource settings: Systematic review’, *JMIR Medical Informatics* **5**(4), e44.