


**LAPORAN PROGRESS PROYEK STBI
SISTEM INFORMASI RETRIEVAL BERBASIS BM25
PADA PLATFORM OPENMRS**



DISUSUN OLEH:

Ade Dwi Prayitno	(25/563076/PPA/07097)
Aldi Indrawan	(25/557923/PPA/07038)
Ari Rudiatama	(25/569437/PPA/07170)
Dimas Ihdam Maulana	(25/562999/PPA/07090)
Wiladahtul Awaliah	(25/569610/PPA/07174)

**PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2026

BAB I — PENDAHULUAN

1.1 Latar Belakang

Penerapan Rekam Medis Elektronik (RME) telah menjadi standar esensial dalam layanan kesehatan modern untuk meningkatkan kualitas dan kontinuitas perawatan pasien. Platform open-source seperti OpenMRS (Open Medical Record System) telah digunakan lebih dari 8.000 fasilitas kesehatan di lebih dari 70 negara untuk mengelola data pasien secara elektronik. OpenMRS menyimpan data klinis dalam berbagai bentuk, termasuk observations, encounters, diagnoses, dan clinical notes berupa teks bebas (free-text) yang mencakup discharge summaries, radiology reports, dan progress notes.

Namun, kemampuan pencarian informasi pada sistem RME konvensional umumnya terbatas pada pencarian eksak (exact-match) berbasis query SQL sederhana. Pendekatan ini tidak efektif untuk menemukan kasus klinis yang relevan dari catatan medis bebas karena tidak memahami sinonim, variasi terminologi medis, atau konteks semantik percakapan klinis. Sebagai contoh, seorang dokter yang mencari pasien dengan “gangguan ginjal kronis” mungkin tidak menemukan catatan yang menggunakan istilah “CKD” atau “penyakit ginjal kronis” jika sistem hanya mendukung pencarian kata kunci eksak.

Information Retrieval (IR) adalah disiplin ilmu yang berfokus pada pengembangan sistem untuk menemukan informasi yang relevan dari koleksi dokumen yang besar. Dalam konteks RME, sistem IR memungkinkan pencarian berbasis konten (content-based search) yang mampu menangkap relevansi semantik antara query pengguna dan isi dokumen medis. Algoritma ranked retrieval seperti BM25 (Best Match 25) telah terbukti menjadi metode state-of-the-art untuk pencarian teks pada koleksi dokumen berskala besar, termasuk dalam domain medis dengan variasi panjang dokumen yang ekstrem.

Tugas besar ini bertujuan untuk mengembangkan dan mengimplementasikan modul IR pada platform OpenMRS menggunakan algoritma BM25. Sistem ini akan memungkinkan pencarian dan perankingan otomatis terhadap catatan medis berbasis teks bebas, sehingga meningkatkan aksesibilitas informasi klinis bagi tenaga medis. Pengembangan dilakukan dalam kurun waktu tujuh sesi pertemuan dengan dataset publik MTSamples sebagai data uji yang mencakup 5.000 transkripsi medis dari 40 spesialisasi klinis.

1.2 Rumusan Masalah

Pencarian informasi medis pada sistem Rekam Medis Elektronik (RME) lama umumnya masih mengandalkan mekanisme pencarian kata kunci eksak yang membatasi efektivitas penemuan kasus klinis dari catatan medis berbasis teks bebas. Pendekatan ini gagal menangani variasi terminologi medis, penggunaan singkatan, dan sinonim yang sering digunakan oleh tenaga medis, sehingga dokumen relevan yang menggunakan istilah berbeda tidak dapat ditemukan. Akibatnya, tenaga medis mengalami kesulitan dan membuang waktu dalam mengakses riwayat klinis pasien yang komprehensif, yang berpotensi menghambat kecepatan serta akurasi pengambilan keputusan medis di fasilitas kesehatan.

1.3 Batasan Proyek

Agar proyek ini tetap fokus dan dapat diselesaikan dalam tujuh sesi pertemuan, ditetapkan batasan sebagai berikut:

1. Platform yang digunakan adalah OpenMRS Reference Application; tidak mencakup pengembangan RME dari nol.
2. Algoritma IR yang diimplementasikan adalah BM25; tidak mencakup pendekatan neural retrieval atau embedding-based.
3. Dataset yang digunakan adalah MTSamples (Medical Transcription Samples) yang berisi 5.000 transkripsi medis dari 40 spesialisasi klinis, diunduh dari Kaggle (<https://www.kaggle.com/tboyle10/medicaltranscriptions>).
4. Modul IR diintegrasikan sebagai komponen tambahan pada OpenMRS melalui REST API, tanpa mengubah skema database inti OpenMRS.
5. Evaluasi dilakukan secara teknis menggunakan metrik IR standar (Precision@K, Recall@K, nDCG dan Mean Response Time) tanpa melibatkan uji klinis dengan pasien nyata.

1.4 Tujuan Proyek

Tujuan proyek ini adalah:

1. Mengimplementasikan algoritma ranked retrieval berbasis BM25 sebagai solusi pencarian yang mampu menangkap relevansi semantik dan menangani variasi terminologi medis pada dokumen teks bebas.
2. Membangun mekanisme pengindeksan dokumen medis yang efisien menggunakan inverted index untuk memproses dan mengelola koleksi data rekam medis berskala besar agar dapat diakses dengan cepat.
3. Mengintegrasikan modul pencarian ke dalam ekosistem OpenMRS melalui arsitektur REST API, sehingga fitur ranked search dapat diakses langsung oleh tenaga medis melalui antarmuka sistem yang ada tanpa mengganggu integritas basis data inti.
4. Mengevaluasi kinerja sistem yang dibangun menggunakan metrik Information Retrieval standar (Precision@K, Recall@K, nDCG dan Mean Response Time) untuk memverifikasi akurasi dan relevansi hasil pencarian dibandingkan dengan metode pencarian konvensional.

1.5 Manfaat Proyek

Manfaat yang diharapkan dari proyek ini meliputi:

1. **Bagi akademik** memberikan pemahaman praktis tentang implementasi IR pada sistem RME open-source dan pemanfaatan dataset klinis publik.
2. **Bagi praktik klinis** menyediakan prototipe modul pencarian cerdas yang dapat membantu tenaga medis menemukan informasi pasien secara lebih cepat dan akurat.
3. **Bagi komunitas OpenMRS** berkontribusi pada pengembangan fitur pencarian berbasis konten yang dapat diadopsi oleh fasilitas kesehatan pengguna OpenMRS.

BAB II — TINJAUAN PUSTAKA

2.1 Information Retrieval dalam Rekam Medis Elektronik

Information Retrieval (IR) dalam konteks kesehatan berkembang pesat seiring dengan pertumbuhan volume data klinis elektronik. Sistem IR pada RME memungkinkan pencarian kasus klinis berdasarkan isi teks medis, bukan hanya metadata pasien. Berbeda dengan pencarian basis data relasional yang bergantung pada exact-match, IR menggunakan model probabilistik atau vektorial untuk menentukan relevansi dokumen terhadap query pengguna. Dalam domain klinis, tantangan IR meliputi variasi terminologi medis (synonymy), singkatan, dan dokumen dengan panjang yang sangat bervariasi, mulai dari radiology report singkat hingga surgery report yang panjang.

2.2 Algoritma BM25

BM25 (Best Match 25) adalah model probabilistik perankingan dokumen yang dikembangkan oleh Robertson et al. (1994) dan merupakan evolusi dari model klasik TF-IDF. BM25 memperhitungkan tiga komponen utama: term frequency (TF) yang di-saturate untuk menghindari dominasi kata yang sangat sering muncul, inverse document frequency (IDF) yang mengukur keunikan kata dalam koleksi, dan normalisasi panjang dokumen untuk mengatasi bias terhadap dokumen yang lebih panjang.

Rumus skoring BM25 untuk dokumen D dan query Q adalah:

$$\text{score}(D, Q) = \sum \text{IDF}(q_i) \cdot [(TF(q_i, D) \cdot (k_1 + 1)) / (TF(q_i, D) + k_1 \cdot (1 - b + b \cdot |D|/\text{avgdl}))]$$

dengan k_1 dan b sebagai parameter tuning. BM25 dipilih dalam proyek ini karena terbukti superior untuk koleksi dokumen dengan variasi panjang yang ekstrem, seperti yang terdapat pada catatan medis (radiology report singkat vs. discharge summary panjang). Pada dataset MTSamples yang mencakup 40 spesialisasi medis, variasi panjang dokumen menjadi sangat signifikan — transkripsi prosedur sederhana mungkin hanya beberapa ratus kata, sementara laporan bedah kompleks dapat mencapai ribuan kata.

2.3 Platform OpenMRS

OpenMRS adalah platform RME open-source yang dikembangkan dengan bahasa pemrograman Java dan arsitektur modular berbasis Spring Framework. Platform ini mendukung pengembangan modul tambahan (OpenMRS Module) yang dapat diinstal secara independen tanpa mengganggu sistem inti. OpenMRS menyediakan REST API bawaan yang memungkinkan

integrasi dengan aplikasi eksternal. Arsitektur modular ini memudahkan pengembangan modul IR sebagai komponen tambahan yang terintegrasi penuh dengan ekosistem OpenMRS.

2.4 Dataset MTSamples

MTSamples (Medical Transcription Samples) adalah dataset publik yang berisi ~5.000 transkripsi medis dari 40 spesialisasi klinis, termasuk Cardiology, Orthopedic, Radiology, Surgery, Neurology, OB/GYN, dan lainnya. Dataset ini tersedia secara gratis di Kaggle (<https://www.kaggle.com/tboyle10/medicaltranscriptions>) dengan klaim lisensi CC0 Public Domain di Kaggle, sehingga pada awalnya diasumsikan dapat digunakan tanpa proses credentialing atau persetujuan etik. (Catatan: status lisensi ini ditinjau ulang pada BAB V setelah ditemukan ambiguitas antara klaim di Kaggle dan situs sumber aslinya.)

Setiap sampel dalam dataset terdiri dari beberapa kolom: `medical_specialty` (spesialisasi), `sample_name` (nama prosedur), `description` (deskripsi singkat), `transcription` (teks bebas lengkap dari transkripsi medis), dan `keywords` (kata kunci yang terkait). Kolom `transcription` berisi paragraf narasi medis lengkap yang secara struktural sangat mirip dengan `discharge summaries` dan `clinical notes` pada sistem RME, mulai dari `preoperative diagnosis`, `procedure description`, hingga `postoperative findings`. Variasi panjang dokumen yang ekstrem pada dataset ini menjadikannya corpus yang ideal untuk evaluasi algoritma BM25.

Kolom `keywords` yang tersedia pada setiap transkripsi awalnya direncanakan dimanfaatkan untuk membangun `query set` dan `relevance judgment` dalam evaluasi metrik IR. Dataset ini telah banyak digunakan dalam penelitian NLP dan IR medis sebagai benchmark alternatif yang lebih mudah diakses dibandingkan dataset klinis terbatas seperti MIMIC-IV yang memerlukan proses credentialing.

2.5 Kajian Pustaka Lanjutan dan Gap Penelitian (Temuan Progress)

Sebagai kelanjutan tinjauan pustaka di atas, dilakukan kajian lanjutan terhadap literatur yang secara spesifik menerapkan BM25 pada korpus MTSamples atau domain klinis sejenis. Hasilnya menunjukkan bahwa BM25 pada MTSamples memang sudah pernah diuji, namun selalu diperlakukan sebagai baseline naif, bukan sebagai objek optimasi tokenisasi.


Studi	Fokus	Perlakuan terhadap BM25
Multi-Corpus Benchmark Study (Mikkelsen, 2026), termasuk korpus MTSamples (n=500)	Membandingkan model embedding dengan BM25 untuk retrieval klinis	BM25 hanya digunakan sebagai baseline dengan tokenisasi lowercase dan penghapusan tanda baca (k1=1,5; b=0,75)
Improved BM25 untuk Precision Medicine (Zhang, BMC Med. Inform. Decis. Mak., 2021)	Optimasi bobot skor BM25 dengan co-word analysis dan Cuckoo Search	Perbaikan difokuskan pada fungsi skor, bukan pada tahap tokenisasi/normalisasi teks

Berdasarkan perbandingan tersebut, gap yang diisi oleh proyek ini adalah: belum ada studi yang secara khusus menguji tokenisasi teks klinis — misalnya penanganan singkatan medis, negasi, dan istilah majemuk — untuk algoritma BM25 pada korpus MTSamples, apalagi yang diintegrasikan langsung ke sistem rekam medis elektronik seperti OpenMRS. Gap inilah yang menjadi kontribusi utama proyek dibandingkan literatur yang sudah ada, dan detail justifikasinya berbasis data korpus sendiri disampaikan pada BAB V.

BAB III — METODOLOGI

3.1 Arsitektur Sistem

Sistem IR yang dikembangkan terdiri dari arsitektur sistem lengkap dengan 4 layer utama: Pengguna (Dokter/UI Dashboard), OpenMRS Platform (Core API + IR Module baru dengan 4 sub-komponen), Data Layer (PostgreSQL + Apache Lucene Index), dan Dataset (MTSamples dengan kolom transcription, keywords, dan medical_specialty). Di bawahnya juga tertera alur kerja 3 fase: Indexing → Query Processing → Integrasi OpenMRS. Arsitektur sistem diilustrasikan pada Gambar 3.1.



Gambar 3.1 Arsitektur Sistem IR pada OpenMRS

3.2 Alur Kerja Sistem

Alur kerja sistem IR terbagi menjadi tiga fase utama:

3.2.1 Fase Indexing

Pada fase ini, seluruh transkripsi medis dari dataset MTSamples diproses melalui preprocessing yang meliputi tokenisasi, case folding, stopwords removal, dan stemming menggunakan algoritma Porter. Hasil preprocessing digunakan untuk membangun inverted index yang menyimpan pemetaan setiap term ke daftar dokumen yang mengandungnya, disertai statistik koleksi (jumlah dokumen N, rata-rata panjang dokumen avgdl, document frequency df, dan term frequency tf). Index ini disimpan menggunakan Apache Lucene dengan konfigurasi BM25 Similarity.

3.2.2 Fase Query Processing

Ketika pengguna mengirimkan query melalui antarmuka OpenMRS, Query Processor melakukan preprocessing yang identik pada query, kemudian mencari term-term query pada inverted index. Sistem menghitung skor BM25 untuk setiap dokumen yang mengandung minimal satu term dari query, mengurutkannya dari skor tertinggi ke terendah, dan mengembalikan daftar dokumen terurut beserta snippet teks yang relevan.

3.2.3 Fase Integrasi OpenMRS

Modul IR dikemas sebagai modul OpenMRS standar (file .omod) yang dapat diinstal melalui Module Management OpenMRS. Modul ini mengekspos endpoint REST GET /ws/rest/v1/ir/search?q={keyword}&limit={k} yang menerima parameter query dan jumlah hasil, kemudian mengembalikan respons JSON berisi daftar dokumen terurut. Antarmuka pengguna sederhana berbasis HTML/JavaScript disediakan sebagai halaman tambahan pada dashboard OpenMRS.

3.3 Dataset dan Preprocessing

Dataset yang digunakan adalah MTSamples dengan karakteristik sebagai berikut:

- Sumber: Kaggle (<https://www.kaggle.com/tboyle10/medicaltranscriptions>)
- Isi: ~5.000 transkripsi medis dari 40 spesialisasi klinis
- Bahasa: Inggris (standar medis internasional)
- Format: CSV (1 file utama)
- Kolom utama: medical_specialty, sample_name, description, transcription, keywords

Preprocessing yang direncanakan meliputi: (1) ekstraksi kolom transcription sebagai dokumen utama, (2) tokenisasi menggunakan whitespace dan punctuation-based tokenizer, (3) case folding ke huruf kecil, (4) stopwords removal menggunakan daftar stopwords bahasa Inggris standar, dan (5) stemming menggunakan algoritma Porter Stemmer. Kolom keywords dimanfaatkan untuk membangun query set evaluasi dan relevance judgment secara semi-otomatis.

Status terkini tahap verifikasi dataset dan pembangunan korpus final pada langkah (1) di atas telah selesai dikerjakan dengan hasil 2.316 dokumen final dari 4.999 baris mentah. Rincian angka, temuan, dan penyesuaian terhadap rencana preprocessing (khususnya pada tokenisasi) disampaikan pada BAB V.

3.4 Metrik Evaluasi

Evaluasi performa sistem IR direncanakan dilakukan menggunakan metrik standar berikut. Query set semula direncanakan dibangun dari kolom keywords pada dataset MTSamples dengan variasi sinonim dan istilah umum, sedangkan relevance judgment ditentukan berdasarkan kecocokan keywords antara query dan dokumen. (Catatan: kelayakan pendekatan ini ditinjau ulang pada BAB V setelah ditemukan bahwa medical_specialty dan secara umum keterkaitan multi-label pada dataset memerlukan penyusunan query set dan relevance judgment secara manual.)

Metrik	Definisi	Target
Precision@K	Proporsi dokumen relevan dari K hasil teratas	≥ 0.70
Recall@K	Proporsi dokumen relevan yang berhasil ditemukan dari total dokumen relevan	≥ 0.60
nDCG@K	Normalized Discounted Cumulative Gain mengukur kualitas ranking dengan memperhatikan posisi dokumen relevan	≥ 0.65
Mean Response Time	Waktu rata-rata sistem memberikan respons query	< 2 detik

BAB IV — JADWAL Pengerjaan

Proyek ini dikerjakan selama tujuh sesi pertemuan dengan alokasi waktu per sesi satu minggu. Setiap sesi memiliki deliverable yang harus diselesaikan sebagai prasyarat untuk sesi berikutnya. Kolom Status Terkini menunjukkan capaian aktual pada saat laporan progress ini disusun (lihat BAB V untuk detail).

Sesi	Topik	Deliverable	Status Terkini
1	Kickoff & Environment Setup	Dokumen proposal final; screenshot OpenMRS berjalan di localhost; repository GitHub dengan struktur awal.	Sebagian reference application ter-clone, modul ter-scaffold namun logika BM25 belum ada.
2	Dataset Preparation	Script preprocessing preprocess.py; file mtsamples_corpus.jsonl; laporan statistik dataset.	Selesai 2.316 dokumen final terverifikasi.
3	BM25 Indexing Engine	Source code indexer; BM25 index file / Lucene index; unit test report.	Berikutnya menunggu keputusan tokenisasi.
4	Query Processing & Ranking	Source code retriever; CLI tool search.py; query set awal (50 query); hasil benchmark pada subset data.	Belum mulai.
5	OpenMRS Integration	File modul .omod; REST API aktif; UI pencarian sederhana (screenshot/demo).	Belum mulai.
6	Evaluation & Optimization	Query set & qrels file (TREC format); tabel evaluasi metrik; analisis perbandingan BM25 vs exact-match.	Belum mulai.
7	Finalization & Presentation	Laporan akhir proyek (PDF).	Belum mulai.

BAB V — LAPORAN PROGRESS: CAPAIAN SAAT INI

Bab ini menyampaikan progres nyata yang dicapai sejak proposal proyek dipresentasikan, dan tidak mengulang materi yang telah disepakati pada BAB I–IV di atas (definisi masalah, pemilihan dataset MTSamples, rumus skor BM25, arsitektur sistem, serta rencana evaluasi).

5.1 Verifikasi Dataset dan Pembangunan Korpus Final

Dataset MTSamples yang sebelumnya masih berupa rencana kini telah diverifikasi dan diproses menjadi korpus final yang siap diindeks. Ringkasan angka hasil pemrosesan disajikan pada tabel berikut.

Baris Mentah	Baris Duplikat	Dokumen Final	Multi-Spesialisasi
4.999	2.609	2.316	91,2%

Adapun langkah-langkah yang sudah dikerjakan mencakup:

- Integritas file CSV MTSamples diverifikasi secara byte-for-byte terhadap statistik resmi yang tercantum di Kaggle, sehingga memastikan tidak ada korupsi atau perubahan data saat diunduh.
- Dibangun pipeline pemrosesan data pada `tools/build_corpus.py` yang bertugas membersihkan data, menggabungkan baris duplikat, dan menyaring dokumen dengan panjang kurang dari 50 token agar korpus akhir hanya berisi transkripsi yang bermakna secara klinis.
- Dataset mentah dan korpus hasil pemrosesan telah di-commit ke repositori tim untuk menjaga reproduksibilitas, sehingga setiap anggota dapat menjalankan ulang pipeline yang sama dan memperoleh hasil identik.

Temuan penting yang diperoleh selama proses ini adalah bahwa kolom `medical_specialty` bersifat multi-label satu transkripsi yang sama dapat dipublikasikan ulang pada lebih dari satu spesialisasi. Kondisi 91,2% dokumen bersifat multi-spesialisasi mengonfirmasi hal tersebut. Implikasinya, kolom `medical_specialty` tidak dapat langsung dijadikan ground-truth relevansi untuk evaluasi Precision/Recall/nDCG pada tahap berikutnya (lihat rencana metrik pada BAB III.4), dan tim perlu menyusun query set serta relevance judgment secara terpisah.

Sumber: [dataset/README.md](#), [corpus_stats.txt](#).

5.2 Justifikasi Tokenisasi Klinis Berbasis Bukti dari Korpus Sendiri

Untuk memastikan urgensi tokenisasi klinis tidak sekadar berdasarkan asumsi, tim melakukan pengukuran langsung pada korpus final (corpus.jsonl, 2.316 dokumen). Tiga temuan utama dirangkum sebagai berikut.

Negasi Klinis	Istilah Majemuk	Singkatan Medis
87,7% dokumen memuat penanda negasi seperti “no”, “denies”, “without”. Stopword list umum cenderung membuang kata-kata ini, padahal maknanya berlawanan (“no fever” vs. “fever”).	21,2% dokumen memuat frasa seperti “shortness of breath”. Tokenizer kata-tunggal memecah frasa ini menjadi token lepas sehingga kehilangan makna sebagai satu konsep utuh.	4,5% dokumen memuat singkatan seperti “c/o”, “DM”, “HTN”. Tokenizer generik memisahkannya menjadi token yang tidak lagi bermakna.

Temuan ini menunjukkan bahwa baseline pada studi-studi sebelumnya (lihat BAB II.5), yang hanya menerapkan lowercasing dan penghapusan tanda baca, akan membuang sinyal klinis yang justru muncul pada sebagian besar dokumen dalam korpus ini. Oleh karena itu, rencana preprocessing pada BAB III.3 disesuaikan: tim akan menerapkan stopwords list klinis yang mempertahankan penanda negasi, disertai stemming khusus istilah medis, dan akan membandingkan hasilnya terhadap baseline tokenisasi naif sebagai pembanding. Pengukuran dilakukan pada corpus.jsonl (2.316 dokumen); rujukan pendukung: Gayen dkk. (2023) dan Griffon dkk. (2012).

5.3 Status Implementasi Modul OpenMRS

Agar sesi berikutnya dapat lebih terarah, status implementasi modul OpenMRS disampaikan secara apa adanya, berdasarkan pemeriksaan langsung terhadap isi repositori openmrs-module-ir-bm25/.

Komponen	Status	Catatan
openmrs-distro-referenceapplication	Selesai	Repositori ter-clone dan siap dijalankan melalui Docker.
Modul ir-bm25 (scaffold SDK)	Sebagian	Service/Dao/Controller/AdminList sudah ter-generate, tetapi isinya masih berupa contoh CRUD bawaan SDK, bukan logika BM25.
Indeks BM25 / Lucene	Belum mulai	Belum ada kode; menunggu keputusan strategi tokenisasi.
REST API /ir/search	Belum mulai	Belum diimplementasikan; kontrak endpoint baru sebatas rancangan.
Query set & relevance judgment	Belum mulai	Belum dibuat; diperlukan sebelum evaluasi Precision/Recall/nDCG.

5.4 Kendala yang Perlu Keputusan Sebelum Sesi Index

- Lisensi dataset: lisensi mtsamples.csv bersifat ambigu. Kaggle mengklaim lisensi CC0, namun mtsamples.com sendiri tidak mencantumkan lisensi eksplisit. Tim perlu menyepakati bagaimana hal ini akan dilaporkan pada laporan akhir.
- Ground truth evaluasi: kolom medical_specialty tidak valid dijadikan label relevansi karena sifatnya multi-label (lihat 5.1). Tim perlu menyusun query set dan relevance judgment secara manual.
- Pilihan tokenizer: belum diputuskan apakah tim akan membangun stopwords list klinis sendiri, atau mengadaptasi pendekatan Essie/UMLS yang sudah tersedia pada literatur.

5.5 Rencana Sesi Berikutnya: Index BM25/Lucene dengan Tokenisasi Klinis

- Mengimplementasikan tokenizer klinis (stopword list yang mempertahankan negasi, ditambah stemming istilah medis) di dalam modul ir-bm25.
- Membangun indeks BM25/Lucene dari corpus.jsonl (2.316 dokumen), dengan varian tokenisasi naif sebagai pembandingan.
- Menyusun draf query set awal untuk digunakan pada uji coba Sesi 4 (Query).

Target sesi berikutnya adalah tersedianya prototipe pencarian yang berjalan sebelum laporan progress berikutnya disampaikan.

BAB VI — KESIMPULAN

Proyek Sistem Information Retrieval berbasis BM25 pada platform OpenMRS diawali dengan proposal yang menetapkan masalah, dataset, arsitektur, dan rencana evaluasi (BAB I–IV). Sejak proposal dipresentasikan, progres nyata telah dicapai: data sudah siap dalam bentuk korpus final terverifikasi sebanyak 2.316 dokumen, gap penelitian pada literatur BM25 untuk teks klinis sudah teridentifikasi dengan jelas, dan arah pengembangan tokenisasi klinis telah tervalidasi langsung menggunakan bukti dari korpus sendiri, bukan asumsi. Modul OpenMRS sudah memiliki kerangka dasar meski logika BM25 belum diimplementasikan. Sesi berikutnya akan difokuskan pada implementasi tokenisasi klinis, pembangunan indeks BM25/Lucene, dan uji coba query pertama, dengan target akhir berupa prototipe pencarian yang dapat berjalan sebelum laporan progress berikutnya.

DAFTAR PUSTAKA

- Apache Lucene. (2026). Apache Lucene Documentation. <https://lucene.apache.org/>
- Gayen, S., Gupta, D., Loane, R. F., Ide, N. C., & Demner-Fushman, D. (2023). Effects of Porting Essie Tokenization and Normalization to Solr. *AMIA Annual Symposium Proceedings*, 2023:369-378. PMID: 38222430
- Griffon, N., Chebil, W., Rollin, L., Kerdelhue, G., Thirion, B., Gehanno, J.-F., & Darmoni, S. J. (2012). Performance evaluation of unified medical language system's synonyms expansion to query PubMed. *BMC Medical Informatics and Decision Making*, 12:12. doi:10.1186/1472-6947-12-12.
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.
- Mikkelsen, Y. (2026). Clinical Context Variables Collectively Rival Model Choice in Embedding-Based Retrieval: Multi-Corpus Benchmark Study. *JMIR Medical Informatics*, 14(1):e94241. doi:10.2196/94241
- MTSamples Medical Transcriptions. Kaggle dataset tboyle10/medicaltranscriptions. <https://www.kaggle.com/datasets/tboyle10/medicaltranscriptions>
- OpenMRS GitHub Organization. (2026). OpenMRS Source Code Repository. <https://github.com/openmrs>
- OpenMRS Wiki. (2026). OpenMRS Documentation. <https://openmrs.atlassian.net/wiki/>
- Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333-389. doi:10.1561/15000000019
- Syzdykova, A., Zieliński, K., & Jackowski, T. (2017). Open-Source Electronic Health Record Systems for Low-Resource Settings: Systematic Review. *JMIR Medical Informatics*, 5(4), e44. <https://doi.org/10.2196/medinform.8131>
- Zhang, Z. (2021). An improved BM25 algorithm for clinical decision support in Precision Medicine based on co-word analysis and Cuckoo Search. *BMC Medical Informatics and Decision Making*, 21:81. doi:10.1186/s12911-021-01454-5