


**PROPOSAL PROYEK STBI
SISTEM INFORMASI RETRIEVAL BERBASIS BM25
PADA PLATFORM OPENMRS**



DISUSUN OLEH:

ADE DWI PRAYITNO	(25/563076/PPA/07097)
ALDI INDRAWAN	(25/557923/PPA/07038)
ARI RUDIATAMA	(25/569437/PPA/07170)
DIMAS IHDAM MAULANA	(25/562999/PPA/07090)
WILADAHTUL AWALIAH	(25/569610/PPA/07174)

**PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA
2026**

BAB I

PENDAHULUAN

1.1 Latar Belakang

Penerapan Rekam Medis Elektronik (RME) telah menjadi standar esensial dalam layanan kesehatan modern untuk meningkatkan kualitas dan kontinuitas perawatan pasien. Platform *open-source* seperti OpenMRS (*Open Medical Record System*) telah digunakan lebih dari 8.000 fasilitas kesehatan di lebih dari 70 negara untuk mengelola data pasien secara elektronik. OpenMRS menyimpan data klinis dalam berbagai bentuk, termasuk *observations*, *encounters*, *diagnoses*, dan *clinical notes* berupa teks bebas (*free-text*) yang mencakup *discharge summaries*, *radiology reports*, dan *progress notes*.

Namun, kemampuan pencarian informasi pada sistem RME konvensional umumnya terbatas pada pencarian eksak (*exact-match*) berbasis query SQL sederhana. Pendekatan ini tidak efektif untuk menemukan kasus klinis yang relevan dari catatan medis bebas karena tidak memahami sinonim, variasi terminologi medis, atau konteks semantik percakapan klinis. Sebagai contoh, seorang dokter yang mencari pasien dengan "gangguan ginjal kronis" mungkin tidak menemukan catatan yang menggunakan istilah "CKD" atau "penyakit ginjal kronis" jika sistem hanya mendukung pencarian kata kunci eksak.

Information Retrieval (IR) adalah disiplin ilmu yang berfokus pada pengembangan sistem untuk menemukan informasi yang relevan dari koleksi dokumen yang besar. Dalam konteks RME, sistem IR memungkinkan pencarian berbasis konten (*content-based search*) yang mampu menangkap relevansi semantik antara query pengguna dan isi dokumen medis. Algoritma *ranked retrieval* seperti **BM25** (*Best Match 25*) telah terbukti menjadi metode *state-of-the-art* untuk pencarian teks pada koleksi dokumen berskala besar, termasuk dalam domain klinis.

Tugas besar ini bertujuan untuk mengembangkan dan mengimplementasikan modul IR pada platform OpenMRS menggunakan algoritma BM25. Sistem ini akan memungkinkan pencarian dan perankingan otomatis terhadap catatan medis berbasis teks bebas, sehingga meningkatkan aksesibilitas informasi klinis bagi tenaga medis. Pengembangan dilakukan dalam kurun waktu tujuh sesi pertemuan dengan dataset publik MIMIC-IV sebagai data uji.

1.2 Rumusan Masalah

Pencarian informasi medis pada sistem Rekam Medis Elektronik (RME) lama umumnya masih mengandalkan mekanisme pencarian kata kunci eksak yang membatasi efektivitas penemuan kasus klinis dari catatan medis berbasis teks bebas. Pendekatan ini gagal menangani variasi terminologi medis, penggunaan singkatan, dan sinonim yang sering digunakan oleh tenaga medis, sehingga dokumen relevan yang menggunakan istilah berbeda tidak dapat ditemukan. Akibatnya, tenaga medis mengalami kesulitan dan membuang waktu dalam mengakses riwayat klinis pasien yang komprehensif, yang berpotensi menghambat kecepatan serta akurasi pengambilan keputusan medis di fasilitas kesehatan.

1.3. Batasan Proyek

Agar proyek ini tetap fokus dan dapat diselesaikan dalam tujuh sesi pertemuan, ditetapkan batasan sebagai berikut:

1. Platform yang digunakan adalah OpenMRS Reference Application; tidak mencakup pengembangan RME dari nol.
2. Algoritma IR yang diimplementasikan adalah BM25; tidak mencakup pendekatan *neural retrieval* atau *embedding-based*.
3. Dataset yang digunakan adalah MIMIC-IV Note Module (versi demo atau subset publik) yang berisi *discharge summaries* dan *radiology reports*.
4. Modul IR diintegrasikan sebagai komponen tambahan pada OpenMRS melalui *REST API*, tanpa mengubah skema database inti OpenMRS.

5. Evaluasi dilakukan secara teknis menggunakan metrik IR standar (Precision@K, Recall@K, nDCG) tanpa melibatkan uji klinis dengan pasien nyata.

1.4 Tujuan Proyek

Tujuan proyek ini adalah:

1. **Mengimplementasikan algoritma *ranked retrieval* berbasis BM25** sebagai solusi pencarian yang mampu menangkap relevansi semantik dan menangani variasi terminologi medis pada dokumen teks bebas.
2. **Membangun mekanisme pengindeksan dokumen medis yang efisien** menggunakan *inverted index* untuk memproses dan mengelola koleksi data rekam medis berskala besar agar dapat diakses dengan cepat.
3. **Mengintegrasikan modul pencarian ke dalam ekosistem OpenMRS** melalui arsitektur REST API, sehingga fitur *ranked search* dapat diakses langsung oleh tenaga medis melalui antarmuka sistem yang ada tanpa mengganggu integritas basis data inti.
4. **Mengevaluasi kinerja sistem yang dibangun** menggunakan metrik *Information Retrieval* standar (Precision@K, Recall@K, dan nDCG) untuk memverifikasi akurasi dan relevansi hasil pencarian dibandingkan dengan metode pencarian konvensional.

1.5 Manfaat Proyek

Manfaat yang diharapkan dari proyek ini meliputi:

1. **Bagi akademik** Memberikan pemahaman praktis tentang implementasi IR pada sistem RME *open-source* dan pemanfaatan dataset klinis publik.
2. **Bagi praktik klinis** Menyediakan prototipe modul pencarian cerdas yang dapat membantu tenaga medis menemukan informasi pasien secara lebih cepat dan akurat.

3. **Bagi komunitas OpenMRS** Berkontribusi pada pengembangan fitur pencarian berbasis konten yang dapat diadopsi oleh fasilitas kesehatan pengguna OpenMRS.

BAB II

TINJAUAN PUSTAKA

2.1 Information Retrieval dalam Rekam Medis Elektronik

Information Retrieval (IR) dalam konteks kesehatan berkembang pesat seiring dengan pertumbuhan volume data klinis elektronik. Sistem IR pada RME memungkinkan pencarian kasus klinis berdasarkan isi teks medis, bukan hanya metadata pasien. Berbeda dengan pencarian basis data relasional yang bergantung pada *exact-match*, IR menggunakan model probabilistik atau vektorial untuk menentukan relevansi dokumen terhadap query pengguna. Dalam domain klinis, tantangan IR meliputi variasi terminologi medis (*synonymy*), singkatan, dan dokumen dengan panjang yang sangat bervariasi.

2.2 Algoritma BM25

BM25 (*Best Match 25*) adalah model probabilistik perankingan dokumen yang dikembangkan oleh Robertson et al. (1994) dan merupakan evolusi dari model klasik TF-IDF. BM25 memperhitungkan tiga komponen utama: *term frequency* (TF) yang di-saturate untuk menghindari dominasi kata yang sangat sering muncul, *inverse document frequency* (IDF) yang mengukur keunikan kata dalam koleksi, dan normalisasi panjang dokumen untuk mengatasi bias terhadap dokumen yang lebih panjang.

Rumus skoring BM25 untuk dokumen D dan query Q adalah:

$$score(D, Q) = \sum IDF(q_i) \cdot \left[(TF(q_i, D) \cdot (k_1 + 1)) / (TF(q_i, D) + k_1 \cdot (1 - b + b \cdot |D|/avgdl)) \right]$$

dengan k_1 dan b sebagai parameter tuning. BM25 dipilih dalam proyek ini karena terbukti superior untuk koleksi dokumen dengan variasi panjang yang ekstrem, seperti yang terdapat pada catatan medis (radiology report singkat vs. discharge summary panjang).

2.3 Platform OpenMRS

OpenMRS adalah platform RME *open-source* yang dikembangkan dengan bahasa pemrograman Java dan arsitektur modular berbasis Spring Framework. Platform ini mendukung pengembangan modul tambahan (*OpenMRS Module*) yang dapat diinstal secara independen tanpa mengganggu sistem inti. OpenMRS menyediakan *REST API* bawaan yang memungkinkan integrasi dengan aplikasi eksternal. Arsitektur modular ini memudahkan pengembangan modul IR sebagai komponen tambahan yang terintegrasi penuh dengan ekosistem OpenMRS.

2.4 Dataset Publik MIMIC-IV

MIMIC-IV (*Medical Information Mart for Intensive Care IV*) adalah database rekam medis elektronik publik yang dikelola oleh MIT Lab for Computational Physiology. Dataset ini berisi data dari lebih dari 180.000 pasien unik yang menjalani perawatan di Beth Israel Deaconess Medical Center (2008–2019). Modul *note* pada MIMIC-IV menyediakan *discharge summaries* dan *radiology reports* dalam bentuk teks bebas yang telah di-*de-identified*. Dataset ini tersedia secara gratis melalui PhysioNet dan telah menjadi standar *de-facto* untuk evaluasi sistem IR dan NLP pada domain klinis.


BAB III

METODOLOGI

3.1 Arsitektur Sistem

Sistem IR yang dikembangkan terdiri dari empat komponen utama yang terintegrasi dalam modul OpenMRS baru, yaitu: (1) *Preprocessing Pipeline*, (2) *Indexing Engine* berbasis BM25, (3) *Query Processor*, dan (4) *REST API Layer*. Arsitektur sistem diilustrasikan pada Gambar 3.1.

Gambar 3.1 Arsitektur Sistem IR pada OpenMRS



3.2 Alur Kerja Sistem

Alur kerja sistem IR terbagi menjadi tiga fase utama:

3.2.1 Fase Indexing

Pada fase ini, seluruh catatan medis dari dataset MIMIC-IV (atau dari database OpenMRS) diproses melalui *preprocessing* yang meliputi tokenisasi, *case folding*, *stopword removal*, dan *stemming* menggunakan algoritma Porter. Hasil preprocessing digunakan untuk membangun *inverted index* yang menyimpan pemetaan setiap term ke daftar dokumen yang mengandungnya, disertai statistik koleksi (jumlah dokumen N , rata-rata panjang dokumen $avgdl$, *document frequency* df , dan *term frequency* tf). Index ini disimpan menggunakan Apache Lucene dengan konfigurasi `BM25Similarity`.

3.2.2 Fase Query Processing

Ketika pengguna mengirimkan query melalui antarmuka OpenMRS, *Query Processor* melakukan preprocessing yang identik pada query, kemudian mencari term-term query pada *inverted index*. Sistem menghitung skor BM25 untuk setiap dokumen yang mengandung minimal satu term dari query, mengurutkannya dari skor tertinggi ke terendah, dan mengembalikan daftar dokumen terurut beserta *snippet* teks yang relevan.

3.2.3 Fase Integrasi OpenMRS

Modul IR dikemas sebagai modul OpenMRS standar (file `.omod`) yang dapat diinstal melalui *Module Management* OpenMRS. Modul ini mengekspos endpoint REST `GET /ws/rest/v1/ir/search?q={keyword}&limit={k}` yang menerima parameter query dan jumlah hasil, kemudian mengembalikan respons JSON berisi daftar dokumen terurut. Antarmuka pengguna sederhana berbasis HTML/JavaScript disediakan sebagai halaman tambahan pada dashboard OpenMRS.

3.3 Dataset dan Preprocessing

Dataset yang digunakan adalah **MIMIC-IV Note Module** dengan karakteristik sebagai berikut:

- **Sumber:** PhysioNet (<https://physionet.org/content/mimic-iv-note/>)
- **Isi:** Discharge summaries dan radiology reports
- **Bahasa:** Inggris (standar medis internasional)
- **Format:** CSV / PostgreSQL dump
- **Preprocessing:** Tokenisasi, lowercasing, stopword removal, stemming

3.4 Metrik Evaluasi

Evaluasi performa sistem IR dilakukan menggunakan metrik standar berikut:

Metrik	Definisi	Target
Precision@K	Proporsi dokumen relevan dari K hasil teratas	≥ 0.70
Recall@K	Proporsi dokumen relevan yang berhasil ditemukan dari total dokumen relevan	≥ 0.60
nDCG@K	<i>Normalized Discounted Cumulative Gain</i> — mengukur kualitas ranking dengan memperhatikan posisi dokumen relevan	≥ 0.65
Mean Response Time	Waktu rata-rata sistem memberikan respons query	< 2 detik

BAB IV

JADWAL Pengerjaan

Proyek ini dikerjakan selama **tujuh sesi pertemuan** dengan alokasi waktu per sesi satu minggu. Setiap sesi memiliki deliverable yang harus diselesaikan sebagai prasyarat untuk sesi berikutnya.

Sesi	Topik	Kegiatan	Deliverable
1	Kickoff & Environment Setup	Instalasi OpenMRS Platform & SDK; setup development environment (Java, Maven, PostgreSQL); download MIMIC-IV demo dataset; studi arsitektur modul OpenMRS.	Dokumen proposal final; screenshot OpenMRS berjalan di localhost; repository GitHub dengan struktur awal.
2	Dataset Preparation	Eksplorasi struktur MIMIC-IV note module; pipeline preprocessing Python (tokenisasi, cleaning, normalisasi); generate cleaned corpus.	Script preprocessing <code>preprocess.py</code> ; file <code>mimic_corpus.jsonl</code> ; laporan statistik dataset (jumlah dokumen, avg length, vocab size).
3	BM25 Indexing Engine	Implementasi <i>inverted index</i> ; kalkulasi statistik BM25 (df, idf, tf, dl, avgdl); penyimpanan index	Source code indexer; BM25 index file / Lucene index; unit test report.

		menggunakan Apache Lucene.	
4	Query Processing & Ranking	Implementasi fungsi scoring BM25; query parser dengan dukungan boolean; ranking dan sorting hasil retrieval.	Source code retriever; CLI tool <code>search.py</code> ; hasil benchmark awal pada subset data.
5	OpenMRS Integration	Pembuatan modul OpenMRS baru; integrasi index engine dengan Service Layer; pembuatan REST API endpoint <code>/ws/rest/v1/ir/search</code> ; UI sederhana.	File modul <code>.omod</code> ; REST API aktif; UI pencarian sederhana (screenshot/demo).
6	Evaluation & Optimization	Pembuatan query set dan <i>relevance judgment</i> (50 query); perhitungan metrik Precision@K, Recall@K, nDCG; tuning parameter BM25 (k_1 , b); perbandingan dengan baseline TF-IDF.	Query set & qrels file (TREC format); tabel evaluasi metrik; analisis perbandingan BM25 vs TF-IDF.
7	Finalization & Presentation	Final testing & bug fixing; penulisan dokumentasi teknis & user guide; demo sistem end-to-end; presentasi hasil.	Laporan akhir proyek (PDF)

DAFTAR PUSTAKA

- Johnson, A. E. W., Bulgarelli, L., Shen, L., Gayles, A., Shammout, A., Horng, S., Pollard, T. J., Hao, S., Moody, B., Gow, B., Lehman, L. H., Celi, L. A., & Mark, R. G. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10(1), 1. <https://doi.org/10.1038/s41597-022-01899-x>
- Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333–389. <https://doi.org/10.1561/15000000019>
- Syzdykova, A., Zieliński, K., & Jackowski, T. (2017). Open-Source Electronic Health Record Systems for Low-Resource Settings: Systematic Review. *JMIR Medical Informatics*, 5(4), e44. <https://doi.org/10.2196/medinform.8131>
- OpenMRS Wiki. (2026). *OpenMRS Documentation*. <https://openmrs.atlassian.net/wiki/>
- OpenMRS GitHub Organization. (2026). *OpenMRS Source Code Repository*. <https://github.com/openmrs>
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.
- Apache Lucene. (2026). *Apache Lucene Documentation*. <https://lucene.apache.org/>