



UNIVERSITAS
GADJAH MADA

Sistem Information Retrieval Berbasis BM25 pada Platform OpenMRS

PROPOSAL PROYEK STBI

Ade Dwi Prayitno	25/563076/PPA/07097
Aldi Indrawan	25/557923/PPA/07038
Ari Rudiantama	25/569437/PPA/07170
Dimas Ihdam Maulana	25/562999/PPA/07090
Wiladahtul Awaliah	25/569610/PPA/07174
Magister Ilmu Komputer - Universitas Gadjah Mada	



UNIVERSITAS
GADJAH MADA

Latar Belakang



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Pencarian Klinis Tidak Cukup Hanya *Exact Match*



UNIVERSITAS
GADJAH MADA

Catatan medis memuat istilah, singkatan, dan variasi penulisan.

Masalah

Kata kunci persis dapat melewati rekam yang memakai istilah berbeda.

Kebutuhan

Dokumen perlu diurutkan menurut relevansi, bukan hanya cocok atau tidak cocok.

Arah solusi

BM25 memberikan perankingan probabilistik yang mempertimbangkan frekuensi istilah dan panjang dokumen.

Tujuan: menemukan rekam klinis yang paling relevan lebih cepat.

Dataset Proyek Dialihkan ke Synthea COVID-19 10K



UNIVERSITAS
GADJAH MADA

Rekam kesehatan sintetis untuk pengembangan dan demonstrasi awal.

Synthea

Synthea menghasilkan rekam kesehatan sintetis. Paket *COVID-19 10K CSV* menyediakan data klinis terstruktur yang dapat dipetakan menjadi korpus pencarian tanpa memakai data pasien nyata.



Mengapa Synthea?

- ▶ Data sintetis.
- ▶ Tersedia dalam CSV, FHIR, dan C-CDA.
- ▶ Ada paket COVID-19 10K dan 100K.
- ▶ Dapat digunakan tanpa pembatasan privasi dan keamanan.

Sumber: <https://synthea.mitre.org/downloads> (diakses 8 Agustus 2026).

Ekspor Lokal Menyediakan Korpus Klinis Berskala Besar



UNIVERSITAS
GADJAH MADA

Statistik dihitung dari file CSV lokal; baris header tidak dihitung.

12.352

pasien

321.528

encounter

1.659.750

observasi

431.262

medikasi

Jenis encounter terbanyak

Wellness	156.219
Ambulatory	86.069
Outpatient	58.367
Inpatient	9.584
Emergency	7.233

Implikasi untuk IR

Korpus dapat dibentuk dari kondisi, observasi, medikasi, prosedur, serta alasan encounter. Unit dokumen dapat ditentukan per pasien atau per encounter.

Sumber: pengolahan langsung dataset/10k_synthea_covid19_csv/*.csv.



UNIVERSITAS
GADJAH MADA

Metodologi



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Tabel CSV Dipetakan Menjadi Dokumen Pencarian Klinis



UNIVERSITAS
GADJAH MADA

Sumber CSV	Kolom yang dipilih	Peran dalam indeks
patients.csv	identitas demografis	<i>patient profile</i>
encounters.csv	kelas, alasan, biaya	konteks encounter
conditions.csv	diagnosis/kondisi	konsep klinis
observations.csv	hasil pengukuran	temuan klinis
medications.csv	obat dan alasan	riwayat terapi
procedures.csv	prosedur dan alasan	tindakan klinis

Strategi awal


Indeks gabungan per pasien atau per encounter, dengan *field* yang dapat diberi bobot sesuai kebutuhan query.

Sumber: struktur file CSV Synthea lokal.

Arsitektur Memisahkan Data, Indeks, dan Layanan Pencarian



UNIVERSITAS
GADJAH MADA



1. Bentuk dokumen

Gabungkan entitas klinis CSV menjadi teks yang dapat dicari.

2. Bangun indeks

Bersihkan teks, hitung statistik koleksi, dan simpan inverted index.

3. Layani query

Terapkan preprocessing yang sama, ranking BM25, dan kembalikan JSON.

BM25 Memberi Skor Berdasarkan Istilah dan Panjang Dokumen



UNIVERSITAS
GADJAH MADA

Fungsi skor

$$\text{score}(D, Q) = \sum_{q_i \in Q} \text{IDF}(q_i) \cdot \frac{\text{TF}(q_i, D) \cdot (k_1 + 1)}{\text{TF}(q_i, D) + k_1 \cdot (1 - b + b \cdot |D|/\text{avgdl})}$$

TF

Term frequency menilai kemunculan istilah query di dalam dokumen.

IDF

Inverse document frequency menaikkan bobot istilah yang jarang.

Normalisasi panjang

Parameter b membantu agar dokumen panjang tidak otomatis unggul.

Parameter yang diuji: k_1 dan b

Baseline: TF-IDF

Sumber: Robertson & Zaragoza (2009).

Query Klinis Mengembalikan Rekam yang Relevan, Bukan Hanya Cocok



UNIVERSITAS
GADJAH MADA

Contoh query

diabetes hypertension medication

Rank	Dokumen	Ringkasan hasil
1	Patient/Encounter A	Diabetes mellitus; hypertension; metformin
2	Patient/Encounter B	Hypertension; glucose monitoring; lifestyle plan
3	Patient/Encounter C	Diabetes follow-up; insulin; HbA1c observation

GET /ws/rest/v1/ir/search?q={keyword}&limit={k}

Contoh hasil bersifat ilustratif.



UNIVERSITAS
GADJAH MADA

Evaluasi dan Rencana Kerja



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Evaluasi Mengukur Relevansi Ranking dan Respons Sistem



UNIVERSITAS
GADJAH MADA

Metrik	Definisi	Target awal
Precision@K	Proporsi dokumen relevan dari K hasil teratas	$\geq 0,70$
Recall@K	Proporsi dokumen relevan yang berhasil ditemukan	$\geq 0,60$
nDCG@K	Kualitas ranking yang memperhitungkan posisi hasil	$\geq 0,65$
Mean Response Time	Waktu rata-rata sistem memberikan respons query	< 2 detik

Rancangan uji

Bangun *query set* dan *relevance judgment*; tuning k_1 dan b ; lalu bandingkan BM25 dengan baseline TF-IDF pada korpus Synthea.

Batasan Menjaga Prototipe Tetap Terukur dan Aman



UNIVERSITAS
GADJAH MADA

Platform dan algoritma

- ▶ OpenMRS Reference Application.
- ▶ BM25 dengan baseline TF-IDF.
- ▶ Tidak mencakup *neural retrieval* atau *embedding-based search*.

Data

- ▶ Synthea COVID-19 10K CSV.
- ▶ Semua rekam bersifat sintetis.
- ▶ Tidak digunakan untuk keputusan klinis nyata.

Dokumen dan integrasi

- ▶ Korpus diturunkan dari entitas CSV terstruktur.
- ▶ Modul tambahan melalui REST API tanpa mengubah skema basis data inti.

Validasi

- ▶ Evaluasi teknis ranking dan respons sistem.
- ▶ Tidak melibatkan uji klinis pada pasien nyata.

Sumber: Synthea Downloads.

Tujuh Sesi Menghasilkan Jalur dari Data ke Demonstrasi



UNIVERSITAS
GADJAH MADA



Deliverable akhir

Modul OpenMRS yang dapat mencari korpus Synthea dan laporan evaluasi kualitas ranking.



UNIVERSITAS
GADJAH MADA

*Synthea: rekam sintetis
untuk prototipe IR klinis.*

Tahap berikutnya: bentuk korpus, indeks dengan BM25, integrasikan REST API, lalu evaluasi kualitas ranking.

***Merakyat, Mandiri, Berkelanjutan
Inclusive, Self-Reliant, Sustainable***

ugm.ac.id