



UNIVERSITAS
GADJAH MADA

Sistem Information Retrieval Berbasis BM25 pada Platform OpenMRS

LAPORAN PROGRESS PROYEK STBI

Ade Dwi Prayitno	25/563076/PPA/07097
Aldi Indrawan	25/557923/PPA/07038
Ari Rudiantama	25/569437/PPA/07170
Dimas Ihdam Maulana	25/562999/PPA/07090
Wiladahtul Awaliah	25/569610/PPA/07174
Magister Ilmu Komputer - Universitas Gadjah Mada	

Yang Sudah Dibahas Minggu Lalu (Tidak Diulang)



UNIVERSITAS
GADJAH MADA

Laporan ini fokus pada progres baru sejak proposal dipresentasikan.

Sudah disepakati

- ▶ Masalah: pencarian klinis butuh perankingan relevansi, bukan *exact match*.
- ▶ Dataset: MTSamples dipilih sebagai korpus.
- ▶ Metodologi: pemetaan kolom CSV, arsitektur (CSV → preprocessing → indeks → REST API → UI), rumus skor BM25.
- ▶ Rencana evaluasi (Precision@K, Recall@K, nDCG@K) dan roadmap 7 sesi.

Isi laporan ini

- ▶ Progres nyata: data diverifikasi & korpus final dibangun.
- ▶ Temuan baru: kajian pustaka dan gap penelitian.
- ▶ Justifikasi tokenisasi berbasis bukti dari korpus sendiri.
- ▶ Status implementasi modul OpenMRS saat ini.
- ▶ Kendala dan rencana sesi berikutnya.



UNIVERSITAS
GADJAH MADA

Progress: Data & Korpus



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Dataset Diverifikasi, Korpus Final Sudah Dibangun



UNIVERSITAS
GADJAH MADA

Bukan lagi rencana: data mentah sudah diproses jadi korpus siap indeks.

4.999

baris mentah

2.609

baris duplikat

2.316

dokumen final

91,2%

multi-spesialisasi

Apa yang sudah dikerjakan

- ▶ Integritas file CSV diverifikasi byte-for-byte terhadap statistik resmi Kaggle.
- ▶ Pipeline `tools/build_corpus.py`: bersihkan, gabungkan duplikat, saring <50 token.
- ▶ Dataset & korpus di-*commit* ke repo untuk reproduksibilitas tim.

Temuan penting

medical_specialty bersifat multi-label (satu transkripsi dipublikasikan ulang di beberapa spesialisasi), **tidak** valid dipakai sebagai *ground-truth* relevansi untuk evaluasi nanti.

Sumber: `dataset/README.md`, `corpus_stats.txt` [1]

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable



UNIVERSITAS
GADJAH MADA

Progress: Kajian Pustaka & Gap



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

BM25 pada MTSamples Sudah Diuji, tapi Sebagai Baseline Naif



UNIVERSITAS
GADJAH MADA

Temuan baru: penelitian terkait belum menysasar optimasi tokenisasi BM25 untuk teks klinis.

Studi	Fokus	Perlakuan BM25
Multi-Corpus Benchmark Study (Mikkelsen, 2026), termasuk korpus MTSamples ($n=500$)	Membandingkan model <i>embedding</i> vs. BM25 untuk retrieval klinis	BM25 hanya sebagai <i>baseline</i> : tokenisasi <i>lowercase</i> + hapus tanda baca ($k_1=1,5$, $b=0,75$)
Improved BM25 untuk <i>Precision Medicine</i> (Zhang, <i>BMC Med. Inform. Decis. Mak.</i> , 2021)	Optimasi bobot skor BM25 dengan <i>co-word analysis</i> + Cuckoo Search	Perbaikan pada fungsi skor, bukan pada tahap tokenisasi/normalisasi teks

Gap yang diisi proyek ini

Belum ada studi yang menguji **tokenisasi khusus teks klinis** (mis. singkatan medis, negasi, istilah majemuk) untuk BM25 pada MTSamples, apalagi yang diintegrasikan langsung ke sistem rekam medis seperti OpenMRS.

Sumber: Mikkelsen (2026) [2]; Zhang (2021) [3].

Tokenisasi Generik Berisiko Membuang Sinyal Klinis Penting



UNIVERSITAS
GADJAH MADA

Urgensi diukur langsung pada korpus sendiri, bukan asumsi.

Negasi klinis

87,7% dokumen memuat penanda negasi ("no", "denies", "without"). *Stopword list* umum membuangnya, padahal maknanya berlawanan ("no fever" vs. "fever").

Istilah majemuk

21,2% dokumen memuat frasa seperti "shortness of breath". *Tokenizer* kata-tunggal memecahnya jadi token lepas, kehilangan makna sebagai satu konsep.

Singkatan medis

4,5% dokumen memuat singkatan seperti "c/o", "DM", "HTN". *Tokenizer* generik memisahkannya jadi token tak bermakna.

Kenapa ini diubah, bukan dipakai apa adanya

Baseline studi sebelumnya hanya *lowercase* + hapus tanda baca: pada korpus ini itu membuang sinyal yang muncul di sebagian besar dokumen. Rencana: *stopword list* klinis (pertahankan negasi) + *stemming* istilah medis, dibandingkan terhadap baseline naif tersebut.

Pengukuran pada `corpus.jsonl` (2.316 dokumen) [1]; rujukan pendukung: Gayen dkk. (2023) [4], Griffon dkk. (2012) [5].



UNIVERSITAS
GADJAH MADA

Status Implementasi



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Tujuh Sesi: Dua Selesai, Lima Menunggu Giliran



UNIVERSITAS
GADJAH MADA



Catatan status

Sesi 1 (Setup): reference application ter-*clone* dan modul OpenMRS ter-*scaffold* (IrBm25Service, IrBm25Dao, IrBm25Controller), tapi **belum ada logika BM25/Lucene di dalamnya**: masih kerangka bawaan SDK.

Modul OpenMRS: Kerangka Ada, Logika BM25 Belum



UNIVERSITAS
GADJAH MADA

Status jujur agar sesi berikutnya terarah.

Komponen	Status	Catatan
openmrs-distro-referenceapplication	Selesai	Repo ter-clone, siap dijalankan via Docker.
Modul ir-bm25 (scaffold SDK)	Sebagian	Service/Dao/Controller/AdminList ter-generate, isinya masih contoh CRUD bawaan, bukan BM25.
Indeks BM25 / Lucene	Belum mulai	Belum ada kode. Menunggu keputusan tokenisasi (lihat slide sebelumnya).
REST API /ir/search	Belum mulai	Belum diimplementasikan; kontrak endpoint baru sebatas rancangan.
Query set & relevance judgment	Belum mulai	Belum dibuat; diperlukan sebelum evaluasi Precision/Recall/nDCG.

Sumber: pemeriksaan langsung isi openmrs-module-ir-bm25/.



UNIVERSITAS
GADJAH MADA

Kendala & Rencana Berikutnya



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Tiga Kendala Perlu Keputusan Sebelum Sesi Index



UNIVERSITAS
GADJAH MADA

Lisensi dataset

Lisensi `mtsamples.csv` ambigu (klaim CCO di Kaggle vs. tanpa lisensi eksplisit di `mtsamples.com`). Perlu disepakati cara melaporkannya di laporan akhir.

Ground truth evaluasi

medical_specialty tidak valid sebagai label relevansi (multi-label). Perlu susun *query set* & *relevance judgment* manual.

Pilihan tokenizer

Belum diputuskan: bangun *stopword list* klinis sendiri, atau adaptasi Essie/UMLS yang sudah ada di literatur.

Sesi Berikutnya: Index BM25/Lucene dengan Tokenisasi Klinis



UNIVERSITAS
GADJAH MADA

Target sesi 3 (Index)

- ▶ Implementasikan *tokenizer* klinis (*stopword list* negasi + *stemming* istilah medis) di dalam modul `ir-bm25`.
- ▶ Bangun indeks BM25/Lucene dari `corpus.jsonl` (2.316 dokumen), dengan varian tokenisasi naif sebagai pembandingan.
- ▶ Susun draf *query set* awal untuk uji coba Sesi 4 (Query).

Target: prototipe pencarian berjalan sebelum laporan progress berikutnya.

1. MTSamples Medical Transcriptions. Kaggle dataset tboyle10/medicaltranscriptions. <https://www.kaggle.com/datasets/tboyle10/medicaltranscriptions>
2. Mikkelsen, Y. (2026). Clinical Context Variables Collectively Rival Model Choice in Embedding-Based Retrieval: Multi-Corpus Benchmark Study. *JMIR Medical Informatics*, 14(1):e94241. doi:10.2196/94241
3. Zhang, Z. (2021). An improved BM25 algorithm for clinical decision support in Precision Medicine based on co-word analysis and Cuckoo Search. *BMC Medical Informatics and Decision Making*, 21:81. doi:10.1186/s12911-021-01454-5
4. Gayen, S., Gupta, D., Loane, R. F., Ide, N. C., & Demner-Fushman, D. (2023). Effects of Porting Essie Tokenization and Normalization to Solr. *AMIA Annual Symposium Proceedings*, 2023:369-378. PMID: 38222430
5. Griffon, N., Chebil, W., Rollin, L., Kerdelhue, G., Thirion, B., Gehanno, J.-F., & Darmoni, S. J. (2012). Performance evaluation of unified medical language system's synonyms expansion to query PubMed. *BMC Medical Informatics and Decision Making*, 12:12. doi:10.1186/1472-6947-12-12
6. Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333-389. doi:10.1561/15000000019



UNIVERSITAS
GADJAH MADA

*Progress minggu ini: data siap,
gap penelitian jelas, arah to-
kenisasi tervalidasi data.*

Sesi berikutnya: implementasikan tokenisasi klinis,
bangun indeks BM25/Lucene, lalu uji coba query
pertama.

***Merakyat, Mandiri, Berkelanjutan
Inclusive, Self-Reliant, Sustainable***

ugm.ac.id