



UNIVERSITAS
GADJAH MADA

Sistem Information Retrieval Berbasis BM25 pada Platform OpenMRS

PROPOSAL PROYEK STBI

Ade Dwi Prayitno	25/563076/PPA/07097
Aldi Indrawan	25/557923/PPA/07038
Ari Rudiantama	25/569437/PPA/07170
Dimas Ihdam Maulana	25/562999/PPA/07090
Wiladahtul Awaliah	25/569610/PPA/07174
Magister Ilmu Komputer - Universitas Gadjah Mada	



UNIVERSITAS
GADJAH MADA

Latar Belakang



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Pencarian Klinis Tidak Cukup Hanya *Exact Match*



UNIVERSITAS
GADJAH MADA

Catatan medis memuat istilah, singkatan, dan variasi penulisan.

Masalah

Kata kunci persis dapat melewati rekam yang memakai istilah berbeda.

Kebutuhan

Dokumen perlu diurutkan menurut relevansi, bukan hanya cocok atau tidak cocok.

Arah solusi

BM25 memberikan perankingan probabilistik yang mempertimbangkan frekuensi istilah dan panjang dokumen.

Tujuan: menemukan rekam klinis yang paling relevan lebih cepat.

Dataset Proyek Beralih ke MTSamples


Koleksi transkripsi medis untuk pengembangan dan evaluasi retrieval teks.



UNIVERSITAS
GADJAH MADA

MTSamples

MTSamples menyediakan contoh transkripsi medis naratif. Kolom *transcription* dapat langsung menjadi dokumen yang diindeks dan diurutkan oleh BM25.



Mengapa MTSamples?

- ▶ Teks bebas siap untuk BM25.
- ▶ Memiliki metadata spesialisasi.
- ▶ Ada *description* dan *keywords*.
- ▶ Cocok untuk uji perankingan dokumen klinis.

Sumber: MTSamples Medical Transcriptions, Kaggle [tboyle10/medicaltranscriptions](https://www.kaggle.com/tboyle10/medicaltranscriptions).

MTSamples Menyediakan Korpus Teks Medis yang Siap Diindeks



UNIVERSITAS
GADJAH MADA

Statistik dihitung dari file CSV lokal; baris header tidak dihitung.

4.999

record

4.966

transkripsi

40

spesialisasi

3.052

rata-rata karakter

Spesialisasi terbanyak

Surgery	1.103
Consult - History and Phy.	516
Cardiovascular / Pulmonary	372
Orthopedic	355
Radiology	273

Implikasi untuk IR

Satu baris MTSamples dapat menjadi satu dokumen. Field *transcription* menjadi isi utama, dengan *specialty*, *description*, dan *keywords* sebagai metadata.

Sumber: pengolahan dataset MTSamples.



UNIVERSITAS
GADJAH MADA

Metodologi



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Kolom MTSamples Dipetakan Menjadi Dokumen Pencarian Klinis



UNIVERSITAS
GADJAH MADA

Sumber CSV	Kolom yang dipilih	Peran dalam indeks
<code>transcription</code>	isi transkripsi medis	dokumen utama BM25
<code>description</code>	ringkasan singkat kasus	konteks dokumen
<code>medical_specialty</code>	bidang spesialisasi	filter atau <i>boost</i>
<code>sample_name</code>	judul contoh catatan	label hasil pencarian
<code>keywords</code>	istilah terkait	perluasan atau <i>boost</i> query

Strategi awal


Indeks satu dokumen per baris MTSamples, dengan *transcription* sebagai field utama dan metadata yang dapat diberi bobot.

Sumber: struktur `mtsamples.csv` lokal.

Arsitektur Memisahkan Data, Indeks, dan Layanan Pencarian



UNIVERSITAS
GADJAH MADA



1. Bentuk dokumen

Gunakan transkripsi medis sebagai dokumen utama yang dapat dicari.

2. Bangun indeks

Bersihkan teks, hitung statistik koleksi, dan simpan inverted index.

3. Layani query

Terapkan preprocessing yang sama, ranking BM25, dan kembalikan JSON.

BM25 Memberi Skor Berdasarkan Istilah dan Panjang Dokumen



UNIVERSITAS
GADJAH MADA

Fungsi skor

$$\text{score}(D, Q) = \sum_{q_i \in Q} \text{IDF}(q_i) \cdot \frac{\text{TF}(q_i, D) \cdot (k_1 + 1)}{\text{TF}(q_i, D) + k_1 \cdot (1 - b + b \cdot |D|/\text{avgdl})}$$

TF

Term frequency menilai kemunculan istilah query di dalam dokumen.

IDF

Inverse document frequency menaikkan bobot istilah yang jarang.

Normalisasi panjang

Parameter b membantu agar dokumen panjang tidak otomatis unggul.

Parameter yang diuji: k_1 dan b

Baseline: TF-IDF

Sumber: Robertson & Zaragoza (2009).

Query Klinis Mengembalikan Rekam yang Relevan, Bukan Hanya Cocok



UNIVERSITAS
GADJAH MADA

Contoh query

diabetes hypertension medication

Rank	Dokumen	Ringkasan hasil
1	Patient/Encounter A	Diabetes mellitus; hypertension; metformin
2	Patient/Encounter B	Hypertension; glucose monitoring; lifestyle plan
3	Patient/Encounter C	Diabetes follow-up; insulin; HbA1c observation

GET /ws/rest/v1/ir/search?q={keyword}&limit={k}

Contoh hasil bersifat ilustratif.



UNIVERSITAS
GADJAH MADA

Evaluasi dan Rencana Kerja



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Evaluasi Mengukur Relevansi Ranking dan Respons Sistem



UNIVERSITAS
GADJAH MADA

Metrik	Definisi	Target awal
Precision@K	Proporsi dokumen relevan dari K hasil teratas	$\geq 0,70$
Recall@K	Proporsi dokumen relevan yang berhasil ditemukan	$\geq 0,60$
nDCG@K	Kualitas ranking yang memperhitungkan posisi hasil	$\geq 0,65$
Mean Response Time	Waktu rata-rata sistem memberikan respons query	< 2 detik

Rancangan uji

Bangun *query set* dan *relevance judgment*; tuning k_1 dan b ; lalu bandingkan BM25 dengan baseline TF-IDF pada korpus MTSamples.

Batasan Menjaga Prototipe Tetap Terukur dan Aman



UNIVERSITAS
GADJAH MADA

Platform dan algoritma

- ▶ OpenMRS Reference Application.
- ▶ BM25 dengan baseline TF-IDF.
- ▶ Tidak mencakup *neural retrieval* atau *embedding-based search*.

Dokumen dan integrasi

- ▶ Korpus berupa transkripsi medis naratif MTSamples.
- ▶ REST API tanpa mengubah skema basis data inti.

Data

- ▶ MTSamples: 4.999 contoh transkripsi medis.
- ▶ Tanpa relasi pasien atau *encounter*.
- ▶ Tidak digunakan untuk keputusan klinis nyata.

Validasi

- ▶ Evaluasi ranking dan respons sistem.
- ▶ Tanpa uji klinis pada pasien nyata.

Tujuh Sesi Menghasilkan Jalur dari Data ke Demonstrasi



UNIVERSITAS
GADJAH MADA



Deliverable akhir

Modul OpenMRS yang dapat mencari korpus MTSamples dan laporan evaluasi kualitas ranking.



UNIVERSITAS
GADJAH MADA

*MTSamples: transkripsi medis
untuk prototipe IR klinis.*

Tahap berikutnya: bentuk korpus, indeks dengan BM25, integrasikan REST API, lalu evaluasi kualitas ranking.

***Merakyat, Mandiri, Berkelanjutan
Inclusive, Self-Reliant, Sustainable***

ugm.ac.id