



UNIVERSITAS
GADJAH MADA

Sistem Information Retrieval Berbasis BM25 pada Platform OpenMRS

PROPOSAL PROYEK STBI

Ade Dwi Prayitno	25/563076/PPA/07097
Aldi Indrawan	25/557923/PPA/07038
Ari Rudiantama	25/569437/PPA/07170
Dimas Ihdam Maulana	25/562999/PPA/07090
Wiladahtul Awaliah	25/569610/PPA/07174
Magister Ilmu Komputer - Universitas Gadjah Mada	



UNIVERSITAS
GADJAH MADA

Latar Belakang



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Pencarian Klinis Tidak Cukup Hanya *Exact Match*



UNIVERSITAS
GADJAH MADA

Catatan medis memuat istilah, singkatan, dan variasi penulisan.

Masalah

Kata kunci persis dapat melewati rekam yang memakai istilah berbeda.

Kebutuhan

Dokumen perlu diurutkan menurut relevansi, bukan hanya cocok atau tidak cocok.

Arah solusi

BM25 memberikan perankingan probabilistik yang mempertimbangkan frekuensi istilah dan panjang dokumen.

Tujuan: menemukan rekam klinis yang paling relevan lebih cepat.

Dataset Proyek Beralih ke MTSamples


Koleksi transkripsi medis untuk pengembangan dan evaluasi retrieval teks.



UNIVERSITAS
GADJAH MADA

MTSamples

MTSamples menyediakan contoh transkripsi medis naratif. Kolom *transcription* dapat langsung menjadi dokumen yang diindeks dan diurutkan oleh BM25.



Mengapa MTSamples?

- ▶ Teks bebas siap untuk BM25.
- ▶ Memiliki metadata spesialisasi.
- ▶ Ada *description* dan *keywords*.
- ▶ Cocok untuk uji perankingan dokumen klinis.

Sumber: MTSamples Medical Transcriptions, Kaggle [tboyle10/medicaltranscriptions](#) [1].

MTSamples Menyediakan Korpus Teks Medis yang Siap Diindeks



UNIVERSITAS
GADJAH MADA

Statistik dihitung dari file CSV lokal; baris header tidak dihitung.

4.999

record

4.966

transkripsi

40

spesialisasi

3.052

rata-rata karakter

Spesialisasi terbanyak (baris mentah)

Surgery	1.103
Consult - History and Phy.	516
Cardiovascular / Pulmonary	372
Orthopedic	355
Radiology	273

Setelah pembersihan korpus

2.609 baris duplikat digabung dan disaring (≥ 50 token) → korpus final **2.316 dokumen**.

medical_specialty multi-label (91,2%), **tidak** layak jadi *ground-truth* relevansi.

Sumber: pengolahan dataset MTSamples [1] (`tools/build_corpus.py`, `corpus_stats.txt`).

Merakyat, Mandiri, Berkelanjutan / Inclusive, Self-Reliant, Sustainable



UNIVERSITAS
GADJAH MADA

Kajian Pustaka & Gap



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

BM25 pada MTSamples Sudah Diuji, tapi Sebagai Baseline Naif



UNIVERSITAS
GADJAH MADA

Penelitian terkait belum menysasar optimasi tokenisasi BM25 untuk teks klinis.

Studi	Fokus	Perlakuan BM25
Multi-Corpus Benchmark Study (Mikkelsen, 2026), termasuk korpus MTSamples ($n=500$)	Membandingkan model <i>embedding</i> vs. BM25 untuk retrieval klinis	BM25 hanya sebagai <i>baseline</i> : tokenisasi <i>lowercase</i> + hapus tanda baca ($k_1=1,5$, $b=0,75$)
Improved BM25 untuk <i>Precision Medicine</i> (Zhang, <i>BMC Med. Inform. Decis. Mak.</i> , 2021)	Optimasi bobot skor BM25 dengan <i>co-word analysis</i> + Cuckoo Search	Perbaikan pada fungsi skor, bukan pada tahap tokenisasi/normalisasi teks

Gap yang diisi proyek ini

Belum ada studi yang menguji **tokenisasi khusus teks klinis** (mis. singkatan medis, negasi, istilah majemuk) untuk BM25 pada MTSamples, apalagi yang diintegrasikan langsung ke sistem rekam medis seperti OpenMRS.

Sumber: Mikkelsen (2026) [2]; Zhang (2021) [3].

Tokenisasi Generik Berisiko Membuang Sinyal Klinis Penting



UNIVERSITAS
GADJAH MADA

Urgensi: baseline lowercase + strip tanda baca tidak cukup untuk transkripsi medis.

Negasi klinis

87,7% dokumen memuat penanda negasi ("no", "denies", "without"). *Stopword list* umum membuangnya, padahal maknanya berlawanan ("no fever" vs. "fever").

Istilah majemuk

21,2% dokumen memuat frasa seperti "shortness of breath". *Tokenizer* kata-tunggal memecahnya jadi token lepas, kehilangan makna sebagai satu konsep.

Singkatan medis

4,5% dokumen memuat singkatan seperti "c/o", "DM", "HTN". *Tokenizer* generik memisahkannya jadi token tak bermakna.

Kenapa ini diubah, bukan dipakai apa adanya

Baseline studi sebelumnya hanya *lowercase* + hapus tanda baca: pada korpus ini itu membuang sinyal yang muncul di sebagian besar dokumen. Rencana: *stopword list* klinis (pertahankan negasi) + *stemming* istilah medis, dibandingkan terhadap baseline naif tersebut.

Pengukuran pada `corpus.jsonl` (2.316 dokumen) [1]; rujukan pendukung: Gayen dkk. (2023) [4], Griffon dkk. (2012) [5].



UNIVERSITAS
GADJAH MADA

Metodologi



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Kolom MTSamples Dipetakan Menjadi Dokumen Pencarian Klinis



UNIVERSITAS
GADJAH MADA

Sumber CSV	Kolom yang dipilih	Peran dalam indeks
<code>transcription</code>	isi transkripsi medis	dokumen utama BM25
<code>description</code>	ringkasan singkat kasus	konteks dokumen
<code>medical_specialty</code>	bidang spesialisasi	filter atau <i>boost</i>
<code>sample_name</code>	judul contoh catatan	label hasil pencarian
<code>keywords</code>	istilah terkait	perluasan atau <i>boost</i> query

Strategi awal


Indeks satu dokumen per baris MTSamples, dengan *transcription* sebagai field utama dan metadata yang dapat diberi bobot.

Sumber: struktur `mtsamples.csv` lokal.

Arsitektur Memisahkan Data, Indeks, dan Layanan Pencarian



UNIVERSITAS
GADJAH MADA



1. Bentuk dokumen

Gunakan transkripsi medis sebagai dokumen utama yang dapat dicari.

2. Bangun indeks

Bersihkan teks, hitung statistik koleksi, dan simpan inverted index.

3. Layani query

Terapkan preprocessing yang sama, ranking BM25, dan kembalikan JSON.

BM25 Memberi Skor Berdasarkan Istilah dan Panjang Dokumen



UNIVERSITAS
GADJAH MADA

Fungsi skor

$$\text{score}(D, Q) = \sum_{q_i \in Q} \text{IDF}(q_i) \cdot \frac{\text{TF}(q_i, D) \cdot (k_1 + 1)}{\text{TF}(q_i, D) + k_1 \cdot (1 - b + b \cdot |D| / \text{avgdl})}$$

TF

Term frequency menilai kemunculan istilah query di dalam dokumen.

IDF

Inverse document frequency menaikkan bobot istilah yang jarang.

Normalisasi panjang

Parameter b membantu agar dokumen panjang tidak otomatis unggul.

Parameter yang diuji: k_1 , b , dan strategi tokenisasi naif

Baseline: TF-IDF & BM25 tokenisasi

Sumber: Robertson & Zaragoza (2009) [6]

Merakyat, Mandiri, Berkelanjutan / Inclusive, Self-Reliant, Sustainable

Query Klinis Mengembalikan Rekam yang Relevan, Bukan Hanya Cocok



UNIVERSITAS
GADJAH MADA

Contoh query

diabetes hypertension medication

Rank	Dokumen	Ringkasan hasil
1	Patient/Encounter A	Diabetes mellitus; hypertension; metformin
2	Patient/Encounter B	Hypertension; glucose monitoring; lifestyle plan
3	Patient/Encounter C	Diabetes follow-up; insulin; HbA1c observation

GET /ws/rest/v1/ir/search?q={keyword}&limit={k}

Contoh hasil bersifat ilustratif.



UNIVERSITAS
GADJAH MADA

Evaluasi dan Rencana Kerja



ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Evaluasi Mengukur Relevansi Ranking dan Respons Sistem



UNIVERSITAS
GADJAH MADA

Metrik	Definisi	Target awal
Precision@K	Proporsi dokumen relevan dari K hasil teratas	$\geq 0,70$
Recall@K	Proporsi dokumen relevan yang berhasil ditemukan	$\geq 0,60$
nDCG@K	Kualitas ranking yang memperhitungkan posisi hasil	$\geq 0,65$
Mean Response Time	Waktu rata-rata sistem memberikan respons query	< 2 detik

Rancangan uji

Bangun *query set* dan *relevance judgment* (bukan dari *medical_specialty*, karena bersifat multi-label); tuning k_1 dan b ; lalu bandingkan BM25 tokenisasi klinis terhadap baseline TF-IDF dan BM25 tokenisasi naif pada korpus MTSamples.

Batasan Menjaga Prototipe Tetap Terukur dan Aman



UNIVERSITAS
GADJAH MADA

Platform dan algoritma

- ▶ OpenMRS Reference Application.
- ▶ BM25 dengan baseline TF-IDF.
- ▶ Tidak mencakup *neural retrieval* atau *embedding-based search*.

Dokumen dan integrasi

- ▶ Korpus berupa transkripsi medis naratif MTSamples.
- ▶ REST API tanpa mengubah skema basis data inti.

Data

- ▶ MTSamples: 4.999 contoh transkripsi medis.
- ▶ Tanpa relasi pasien atau *encounter*.
- ▶ Tidak digunakan untuk keputusan klinis nyata.

Validasi

- ▶ Evaluasi ranking dan respons sistem.
- ▶ Tanpa uji klinis pada pasien nyata.

Tujuh Sesi Menghasilkan Jalur dari Data ke Demonstrasi



UNIVERSITAS
GADJAH MADA



Deliverable akhir

Modul OpenMRS yang dapat mencari korpus MTSamples dan laporan evaluasi kualitas ranking.

1. MTSamples Medical Transcriptions. Kaggle dataset tboyle10/medicaltranscriptions. <https://www.kaggle.com/datasets/tboyle10/medicaltranscriptions>
2. Mikkelsen, Y. (2026). Clinical Context Variables Collectively Rival Model Choice in Embedding-Based Retrieval: Multi-Corpus Benchmark Study. *JMIR Medical Informatics*, 14(1):e94241. doi:10.2196/94241
3. Zhang, Z. (2021). An improved BM25 algorithm for clinical decision support in Precision Medicine based on co-word analysis and Cuckoo Search. *BMC Medical Informatics and Decision Making*, 21:81. doi:10.1186/s12911-021-01454-5
4. Gayen, S., Gupta, D., Loane, R. F., Ide, N. C., & Demner-Fushman, D. (2023). Effects of Porting Essie Tokenization and Normalization to Solr. *AMIA Annual Symposium Proceedings*, 2023:369-378. PMID: 38222430
5. Griffon, N., Chebil, W., Rollin, L., Kerdelhue, G., Thirion, B., Gehanno, J.-F., & Darmoni, S. J. (2012). Performance evaluation of unified medical language system's synonyms expansion to query PubMed. *BMC Medical Informatics and Decision Making*, 12:12. doi:10.1186/1472-6947-12-12
6. Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333-389. doi:10.1561/15000000019



UNIVERSITAS
GADJAH MADA

*MTSamples: transkripsi medis
untuk prototipe IR klinis.*

Tahap berikutnya: bentuk korpus, indeks dengan BM25, integrasikan REST API, lalu evaluasi kualitas ranking.

***Merakyat, Mandiri, Berkelanjutan
Inclusive, Self-Reliant, Sustainable***

ugm.ac.id