UNIVERSITAS GADJAH MADA

Sistem Information Retrieval Berbasis BM25 pada Platform OpenMRS

LAPORAN AKHIR PROYEK STBI

Ade Dwi Prayitno	25/563076/PPA/07097
Aldi Indrawan	25/557923/PPA/07038
Ari Rudiatama	25/569437/PPA/07170
Dimas Ihdam Maulana	25/562999/PPA/07090
Wiladahtul Awaliah	25/569610/PPA/07174

Magister Ilmu Komputer - Universitas Gadjah Mada

ugm.ac.id

Merakyat, Mandiri, Berkelanjutan
Inclusive, Self-Reliant, Sustainable

Ringkasan Proyek

UNIVERSITAS GADJAH MADA

Masalah & tujuan

- Pencarian RME *exact-match* gagal menangani sinonim, singkatan, dan variasi terminologi medis.
- Tujuan: modul IR berbasis BM25 di OpenMRS yang menangkap relevansi semantik teks klinis.
- Dataset: MTSamples (∼5.000 transkripsi, 40 spesialisasi).

Kontribusi

- Bukan sekadar "BM25 di dataset medis": studi ablasi lapisan normalisasi + ekspansi klinis.
- 5 varian retrieval (V0–V4) dibandingkan berdampingan.
- Modul OpenMRS + endpoint JSON + UI dropdown, teruji berjalan.
- Evaluasi TREC-style: P@K, Recall@K, nDCG@K.

UNIVERSITAS GADJAH MADA

Data & Dataset

ugm.ac.id

Merakyat, Mandiri, Berkelanjutan | Inclusive, Self-Reliant, Sustainable

Dari 4.999 Baris ke 2.316 Dokumen

UNIVERSITAS GADJAH MADA

4.999 baris mentah	**2.609** baris duplikat	**2.316** dokumen final	**91,2%** multi-spesialisasi

Apa yang dikerjakan

- Pipeline `tools/build_corpus.py`: bersihkan, gabungkan duplikat, saring <50 token.
- Duplikat digabung (bukan dibuang) agar metadata multi-label dipertahankan.

Sumber: `dataset/README.md`, `corpus_stats.txt` [1].

Kajian Pustaka & Gap

BM25 di MTSamples: Sebatas Baseline

UNIVERSITAS GADJAH MADA

Studi	Fokus	Perlakuan BM25
Multi-Corpus Benchmark Study (Mikkelsen, 2026), termasuk dataset MTSamples ($n=500$)	Membandingkan model *embedding* vs. BM25 untuk retrieval klinis	BM25 hanya *baseline*: tokenisasi *lowercase* + hapus tanda baca ($k_1=1{,}5$, $b=0{,}75$)
Improved BM25 untuk *Precision Medicine* (Zhang, 2021)	Optimasi bobot skor BM25 (*co-word* + Cuckoo Search)	Perbaikan fungsi skor, bukan tokenisasi/normalisasi
Gayen dkk. (2023): Essie $\rightarrow$ Solr	Tokenisasi klinis di Solr	Bukan untuk BM25 di RME
Griffon dkk. (2012): UMLS synonyms	Ekspansi sinonim UMLS	Untuk PubMed, bukan RME

Sumber: Mikkelsen (2026) [2], Zhang (2021) [3], Gayen dkk. (2023) [4], Griffon dkk. (2012) [5].

Urgensi Diukur Langsung pada Dataset

UNIVERSITAS GADJAH MADA

Negasi klinis

88,0% dokumen (13 term). *Stopword list* umum membuang "no/denies/without", padahal maknanya berlawanan.

Istilah majemuk

60,9% dokumen (28 frasa). *Tokenizer* kata-tunggal memecah "shortness of breath" jadi token lepas.

Singkatan medis

28,8% dokumen (28 singkatan). "c/o", "DM", "HTN", "CKD" tak bermakna bila dipecah generik.

Implikasi

Baseline sebelumnya (lowercase + hapus tanda baca) membuang sinyal yang muncul di sebagian besar dokumen. Solusi: normalisasi klinis (negasi dipertahankan, majemuk dikolaps, singkatan diekspansi) + ekspansi sinonim, dibandingkan ablation terhadap baseline naif.

Pengukuran pada `corpus.jsonl` (2.316 dokumen) via `tools/build_lexicon.py`.

UNIVERSITAS GADJAH MADA

Implementasi

Lima Varian Retrieval (Ablation Study)

UNIVERSITAS GADJAH MADA

ID	Label	Strategi
V0	Naive BM25	lowercase + hapus tanda baca (baseline)
V1	Normalisasi klinis	V0 + negasi dipertahankan + istilah majemuk + ekspansi singkatan
V2	Klinis + ekspansi	V1 + ekspansi sinonim *query-side*
V3	Char n-gram	indexing karakter n-gram (3-5)
V4	Klinis + ekspansi + PRF	V2 + *pseudo-relevance feedback*

Parameter BM25 identik pada kelima varian ($k_1 = 1{,}2$, $b = 0{,}75$); fungsi skor: Robertson & Zaragoza (2009) [6].

Penjelasan Tiap Teknik

Negasi dipertahankan (V1)
Penanda seperti `no`, `denies`, `without` biasanya dibuang *stopword list* umum. Di sini dipertahankan agar makna klinis tidak terbalik (mis. "no fever" ≠ "fever").

Istilah majemuk dikolaps (V1)
Frasa seperti "shortness of breath" diperlakukan sebagai satu unit makna, bukan dipecah menjadi token lepas oleh *tokenizer* kata-tunggal.

Ekspansi singkatan (V1)
Singkatan medis (`DM`, `HTN`, `CKD`, dst.) diekspansi dua arah, saat *indexing* dan saat *query*, sehingga bentuk singkat dan panjang saling ditemukan.

Ekspansi sinonim (V2)
Istilah awam pengguna (mis. "high blood pressure") diperluas ke istilah medis (mis. "hypertension") hanya di sisi *query*, tanpa mengubah index.

Char n-gram (V3)
Dokumen diindeks berbasis potongan karakter (3-5 huruf), bukan kata utuh, sehingga tahan terhadap salah ketik dan variasi morfologi tanpa bergantung pada *lexicon*.

Pseudo-relevance feedback (V4)
Ekspansi query otomatis: term yang sering muncul pada dokumen teratas hasil pencarian awal ditambahkan ke query, tanpa kamus manual.

UNIVERSITAS GADJAH MADA

Hasil & Evaluasi

Hasil Evaluasi Lima Varian

Varian	P@10	Recall@10	nDCG@10
V0 · Naive BM25	0,5400	**0,4312**	0,6832
V1 · Normalisasi klinis	**0,5420**	0,4284	**0,6865**
V2 · Klinis + ekspansi	0,5120	0,4192	0,6509
V3 · Char n-gram	0,5280	0,4055	0,6446
V4 · Klinis + ekspansi + PRF	0,5020	0,4139	0,6186

Temuan

Selisih V1 vs V0 sangat kecil: nDCG +0,0033 dan P@10 +0,0020, setara **1 dokumen** dari 500 posisi terambil. Recall@10 justru turun. Belum ada uji signifikansi ⇒ klaim yang aman: normalisasi klinis **tidak menurunkan** kualitas, dengan respons 3,6× lebih cepat (0,68 vs 2,48 ms).

Verifikasi fungsional

Query “CKD” → menemukan “Chronic Kidney Disease - Followup”. Query “hypertension” → menemukan dokumen ber-“HTN”.

Sumber: `eval/results.txt`, dijalankan via `EvalRunner`.

Demo: Mode “Bandingkan Semua”

UNIVERSITAS GADJAH MADA

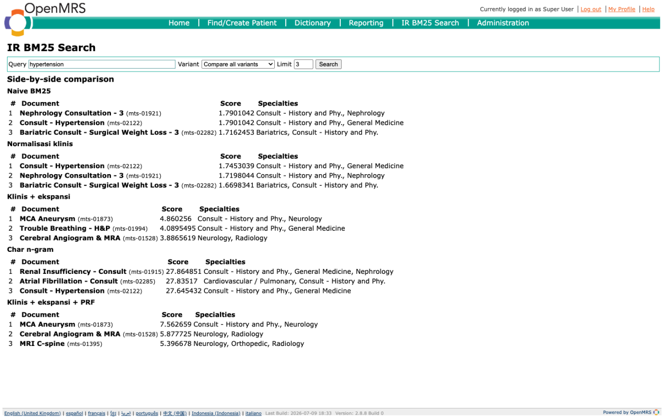

IR BM25 Search

Side-by-side comparison

Naive BM25

#	Document	Score	Specialties
1	**Nephrology Consultation - 3** (mts-01921)	1.7901042	Consult - History and Phy., Nephrology
2	**Consult - Hypertension** (mts-02122)	1.7901042	Consult - History and Phy., General Medicine
3	**Bariatric Consult - Surgical Weight Loss - 3** (mts-02282)	1.7162453	Bariatrics, Consult - History and Phy.

Normalisasi klinis

#	Document	Score	Specialties
1	**Consult - Hypertension** (mts-02122)	1.7453039	Consult - History and Phy., General Medicine
2	**Nephrology Consultation - 3** (mts-01921)	1.7198044	Consult - History and Phy., Nephrology
3	**Bariatric Consult - Surgical Weight Loss - 3** (mts-02282)	1.6698341	Bariatrics, Consult - History and Phy.

Klinis + ekspansi

#	Document	Score	Specialties
1	**MCA Aneurysm** (mts-01873)	4.860256	Consult - History and Phy., Neurology
2	**Trouble Breathing - H&P** (mts-01994)	4.0895495	Consult - History and Phy., General Medicine
3	**Cerebral Angiogram & MRA** (mts-01528)	3.8865619	Neurology, Radiology

Char n-gram

#	Document	Score	Specialties
1	**Renal Insufficiency - Consult** (mts-01915)	27.864851	Consult - History and Phy., General Medicine, Nephrology
2	**Atrial Fibrillation - Consult** (mts-02285)	27.83517	Cardiovascular / Pulmonary, Consult - History and Phy.
3	**Consult - Hypertension** (mts-02122)	27.645432	Consult - History and Phy., General Medicine

Klinis + ekspansi + PRF

#	Document	Score	Specialties
1	**MCA Aneurysm** (mts-01873)	7.562659	Consult - History and Phy., Neurology
2	**Cerebral Angiogram & MRA** (mts-01528)	5.877725	Neurology, Radiology
3	**MRI C-spine** (mts-01395)	5.396678	Neurology, Orthopedic, Radiology

Tangkapan layar modul `ir-bm25` pada OpenMRS Legacy UI.

Demo: Ekspansi Singkatan

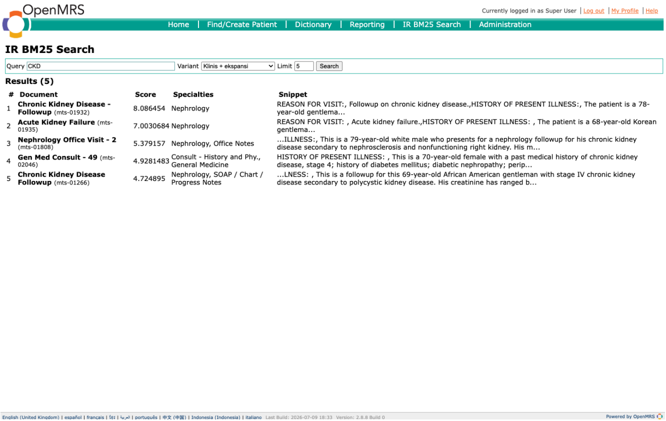

#	Document	Score	Specialties	Snippet
1	**Chronic Kidney Disease - Followup** (mts-01932)	8.086454	Nephrology	REASON FOR VISIT:, Followup on chronic kidney disease.,HISTORY OF PRESENT ILLNESS:, The patient is a 78-year-old gentlema...
2	**Acute Kidney Failure** (mts-01935)	7.0030684	Nephrology	REASON FOR VISIT: , Acute kidney failure.,HISTORY OF PRESENT ILLNESS: , The patient is a 68-year-old Korean gentlema...
3	**Nephrology Office Visit - 2** (mts-01808)	5.379157	Nephrology, Office Notes	...ILLNESS:, This is a 79-year-old white male who presents for a nephrology followup for his chronic kidney disease secondary to nephrosclerosis and nonfunctioning right kidney. His m...
4	**Gen Med Consult - 49** (mts-02046)	4.9281483	Consult - History and Phy., General Medicine	HISTORY OF PRESENT ILLNESS: , This is a 70-year-old female with a past medical history of chronic kidney disease, stage 4; history of diabetes mellitus; diabetic nephropathy; perip...
5	**Chronic Kidney Disease Followup** (mts-01266)	4.724895	Nephrology, SOAP / Chart / Progress Notes	...LNESS: , This is a followup for this 69-year-old African American gentleman with stage IV chronic kidney disease secondary to polycystic kidney disease. His creatinine has ranged b...

Tangkapan layar hasil pencarian (variant v2).

UNIVERSITAS GADJAH MADA

Kesimpulan

Kesimpulan

UNIVERSITAS GADJAH MADA

Apa yang dicapai

- Mesin IR BM25 dengan lapisan normalisasi + ekspansi klinis, terintegrasi ke OpenMRS sebagai modul.
- Ablation study 5 varian pada dataset MTSamples (2.316 dokumen).
- Validasi berbasis data: negasi/majemuk/singkatan muncul di mayoritas dokumen.
- Hasil: V1 unggul tipis atas baseline naif, namun selisihnya dalam rentang *noise* $\Rightarrow$ klaim dibatasi pada “tidak menurunkan kualitas, respons lebih cepat”.
- Keterbatasan qrels (metadata vs transkripsi) diidentifikasi dan menjelaskan sebagian besar penurunan varian ekspansi.
- Purwarupa pencarian cerdas yang siap dipakai dan dapat diperluas.

Daftar Pustaka

UNIVERSITAS GADJAH MADA

1. MTSamples Medical Transcriptions. Kaggle dataset `tboyle10/medicaltranscriptions`. `https://www.kaggle.com/datasets/tboyle10/medicaltranscriptions`
2. Mikkelsen, Y. (2026). Clinical Context Variables Collectively Rival Model Choice in Embedding-Based Retrieval: Multi-Corpus Benchmark Study. *JMIR Medical Informatics*, 14(1):e94241. `doi:10.2196/94241`
3. Zhang, Z. (2021). An improved BM25 algorithm for clinical decision support in Precision Medicine based on co-word analysis and Cuckoo Search. *BMC Medical Informatics and Decision Making*, 21:81. `doi:10.1186/s12911-021-01454-5`
4. Gayen, S., Gupta, D., Loane, R. F., Ide, N. C., & Demner-Fushman, D. (2023). Effects of Porting Essie Tokenization and Normalization to Solr. *AMIA Annual Symposium Proceedings*, 2023:369-378. PMID: 38222430
5. Griffon, N., Chebil, W., Rollin, L., Kerdelhue, G., Thirion, B., Gehanno, J.-F., & Darmoni, S. J. (2012). Performance evaluation of unified medical language system's synonyms expansion to query PubMed. *BMC Medical Informatics and Decision Making*, 12:12. `doi:10.1186/1472-6947-12-12`
6. Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333-389. `doi:10.1561/1500000019`

UNIVERSITAS GADJAH MADA

Terima Kasih

"Kita tenggelam dalam informasi, namun kehausan akan kebijaksanaan." - E. O. Wilson

Merakyat, Mandiri, Berkelanjutan
Inclusive, Self-Reliant, Sustainable

ugm.ac.id